

Análises de Estímulos Musicais

Frederico Pedrosa

2025-12-03

Contents

1 Set Up	2
1.1 Arrumando o data	3
1.2 Transformar em formato longo	4
2 Seleção de melhores estímulos por TRI de 2pl	5
2.1 Felicidade	5
2.2 Medo/Raiva	7
2.3 Serenidade	8
2.4 Tristeza	9
3 Criar data frame com os melhores itens de cada categoria	10
4 Análise Fatorial Confirmatória das três categorias com estímulos adequados	11
4.1 Modelo com 3 dimensões	11
4.2 Modelo Unidimensional	15
4.3 Modelo Bifatorial	19
4.4 Fator de Segunda Ordem	20
4.5 Aqui considerar só a confiabilidade do Fator Geral	24
5 Correlação com BDI e BAI	24
5.1 Correlações	25
6 Modelos mistos	27
6.1 Arrumar o data	27
6.2 Modelo misto para ansiedade	28
6.3 Modelo misto para depressão	30

7 Variáveis SD	34
7.1 Músicos X Não-Músicos	35
7.2 Anos de estudo musical	36
7.3 Sexo e Idade	37
7.4 Músicos têm maior Habilidade Geral (G)?	38
7.5 Não linearidade	39

Desenho do Estudo

O estudo avaliou 200 participantes (100 músicos e 100 não-músicos, 18-40 anos) em uma tarefa de reconhecimento emocional. Foram utilizados 116 estímulos musicais inéditos, compostos para evocar quatro emoções distintas (Alegria, Medo/Raiva, Tristeza e Serenidade), representantes dos 4 quadrantes do Modelo Circumplexo. A tarefa consistiu em identificar a emoção percebida em cada estímulo (Acurácia/Congruência) e avaliar valência e alerta (SAM). Variáveis de controle incluíram BDI, BAI e questionário musical.

Resumo

Unidimensionalidade Hierárquica A Análise Fatorial Confirmatória (CFA) indicou que um Fator Geral de Habilidade (G_ability) explica a vasta maioria da variância das emoções específicas (Felicidade, Medo/Raiva, Tristeza), com confiabilidade excelente ($\alpha = 0.92$).

Estabilidade Clínica Modelos Mistos e Random Forest confirmaram que o desempenho no teste não é influenciado por sintomatologia ansiosa (BAI) ou depressiva (BDI). A variância explicada pelo Random Forest foi negativa (-14%), comprovando a ausência de vieses não-lineares associados à psicopatologia.

Independência de Treino: Não houve diferença significativa entre músicos e não-músicos, nem influência da escolaridade ou idade.

Preditação: A única variável preditora significativa foi o Sexo ($p = .023$) no modelo linear; nó raiz na árvore de decisão, com mulheres apresentando uma leve vantagem no reconhecimento emocional.

1 Set Up

```
## Warning: package 'tidyverse' was built under R version 4.3.2

## Warning: package 'ggplot2' was built under R version 4.3.2

## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr     1.1.4    v purrr     1.0.2
## vforcats   1.0.0    v readr      2.1.5
## v ggplot2   3.5.1    v stringr    1.5.1
## v lubridate 1.9.3    v tibble     3.2.1
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()   masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
## Loading required package: MASS
##
##
## Attaching package: 'MASS'
##
##
## The following object is masked from 'package:dplyr':
```

```

##      select
##
## Loading required package: msm

## Warning: package 'msm' was built under R version 4.3.3

## Loading required package: polycor

## Warning: package 'lavaan' was built under R version 4.3.3

## This is lavaan 0.6-18
## lavaan is FREE software! Please report any bugs.
##
#####
## This is semTools 0.5-6
## All users of R (or SEM) are invited to submit functions or ideas for functions.
#####
## Loading required package: Matrix
##
## Attaching package: 'Matrix'
##
## The following objects are masked from 'package:tidyverse':
##
##     expand, pack, unpack

## Warning: package 'sjPlot' was built under R version 4.3.3

## Warning: package 'rpart.plot' was built under R version 4.3.2

## randomForest 4.7-1.1
## Type rfNews() to see new features/changes/bug fixes.

## Warning: package 'ggeffects' was built under R version 4.3.3

## [conflicted] Will prefer dplyr::select over any other package.
## New names:

```

1.1 Arrumando o data

```

# 1. Definir os números sequenciais de 1 a 116, formatados com zeros à esquerda (001, 002, ..., 116)
stimuli_numbers <- sprintf("%03d", 1:116)

# 2. Renomear o grupo de Emoção Percebida (colunas 27 a 142)
names(data)[27:142] <- paste0("Emotion_St_", stimuli_numbers)

# 3. Renomear o grupo de Congruência (colunas 144 a 259)
names(data)[144:259] <- paste0("Congruence_St_", stimuli_numbers)

```

```

# 4. Renomear o grupo de Arousal (colunas 267 a 382)
names(data)[267:382] <- paste0("Arousal_St_", stimuli_numbers)

# 5. Renomear o grupo de Valence (colunas 384 a 499)
names(data)[384:499] <- paste0("Valence_St_", stimuli_numbers)

# 6. (Recomendado) Remover as colunas vazias se estiverem em branco
data <- data[, -c(26, 143, 266, 383)] # Remove as colunas pelos indices

# 7. Verifique o resultado
head(names(data))

## [1] "Participants" "Group"          "Order"        "Education"     "Sex"
## [6] "Age"

```

1.2 Transformar em formato longo

```

# 1. Pivatar as respostas de EMOÇÃO PERCEBIDA (com o prefixo correto)
emotion_long <- data %>%
  select(Participants, Group, starts_with("Emotion_St_")) %>%
  pivot_longer(
    cols = -c(Participants, Group),
    names_to = "Stimulus_ID",
    names_prefix = "Emotion_St_", # <--- AJUSTE AQUI
    values_to = "Perceived_Emotion"
  )

# 2. Pivatar as respostas de CONGRUÊNCIA
congruence_long <- data %>%
  select(Participants, starts_with("Congruence_St_")) %>%
  pivot_longer(
    cols = -Participants,
    names_to = "Stimulus_ID",
    names_prefix = "Congruence_St_",
    values_to = "Congruence"
  )

# 3. Pivatar as respostas de AROUSAL
arousal_long <- data %>%
  select(Participants, starts_with("Arousal_St_")) %>%
  pivot_longer(
    cols = -Participants,
    names_to = "Stimulus_ID",
    names_prefix = "Arousal_St_",
    values_to = "Arousal"
  )

# 4. Pivatar as respostas de VALÊNCIA
valence_long <- data %>%
  select(Participants, starts_with("Valence_St_")) %>%
  pivot_longer(

```

```

    cols = -Participants,
    names_to = "Stimulus_ID",
    names_prefix = "Valence_St_",
    values_to = "Valence"
  )

# 5. Juntar tudo em um único dataframe longo
data_long <- emotion_long %>%
  left_join(congruence_long, by = c("Participants", "Stimulus_ID")) %>%
  left_join(arousal_long, by = c("Participants", "Stimulus_ID")) %>%
  left_join(valence_long, by = c("Participants", "Stimulus_ID")) %>%
  mutate(Stimulus_ID = as.numeric(Stimulus_ID)) # Agora isso vai funcionar!

# 6. Adicionar a coluna com a EMOÇÃO PRETENDIDA para cada estímulo
data_long <- data_long %>%
  mutate(
    Intended_Emotion = case_when(
      Stimulus_ID <= 29 ~ "Happiness",
      Stimulus_ID <= 58 ~ "Fear/Anger",
      Stimulus_ID <= 87 ~ "Serenity",
      TRUE ~ "Sadness"
    )
  )

# 7. Verifique o resultado (agora deve estar correto)
head(data_long)

```

```

## # A tibble: 6 x 8
##   Participants Group Stimulus_ID Perceived_Emotion Congruence Arousal Valence
##       <dbl> <dbl>     <dbl>           <dbl>      <dbl>     <dbl>    <dbl>
## 1          1     1         1             2        0       6      1
## 2          1     1         2             4        1       6      6
## 3          1     1         3             2        1       5      2
## 4          1     1         4             2        0       6      1
## 5          1     1         5             2        1       6      1
## 6          1     1         6             2        1       9      1
## # i 1 more variable: Intended_Emotion <chr>

```

2 Seleção de melhores estímulos por TRI de 2pl

2.1 Felicidade

```

# --- Criar o Dataframe Largo Completo ---
all_responses_wide <- data_long %>%
  dplyr::select(Participants, Stimulus_ID, Congruence) %>%

pivot_wider(
  names_from = Stimulus_ID,
  values_from = Congruence,
  names_prefix = "St_"

```

```

)

# --- TRI para "Felicidade" usando o dataframe completo ---

# 1. Definir os nomes das colunas de "Felicidade" (Estímulos 1 a 29)
happiness_cols <- paste0("St_", 1:29)

# 2. Selecionar apenas essas colunas para a análise
happiness_response_matrix <- all_responses_wide %>%
  dplyr::select(all_of(happiness_cols))

# 3. Rodar o modelo TRI 2PL
model_happiness <- ltm(happiness_response_matrix ~ z1, IRT.param = TRUE)

# --- PASSO 3: Analisar e Exibir os Resultados ---

# Extrair e organizar os coeficientes
coef_happiness <- as.data.frame(coef(model_happiness))

results_happiness <- coef_happiness %>%
  rename(Difficulty = Dffclt, Discrimination = Dscrmn) %>%
  rownames_to_column(var = "Stimulus_ID") %>%
  mutate(Stimulus_ID = as.numeric(str_replace(Stimulus_ID, "St_", ""))) %>%
  arrange(desc(Discrimination)) # Ordena pelos itens mais discriminativos

# Mostrar os resultados
print("--- Parâmetros dos Itens para Felicidade (ordenado por Discriminação) ---")

```

```
## [1] "--- Parâmetros dos Itens para Felicidade (ordenado por Discriminação) ---"
```

```
print(results_happiness)
```

	Stimulus_ID	Difficulty	Discrimination
## 1	6	-1.4864795	1.97321170
## 2	13	-1.4390486	1.62780637
## 3	15	-0.7850875	1.61261607
## 4	14	-1.5444820	1.24666211
## 5	19	-2.3341774	1.17551433
## 6	3	-1.3953428	1.15476762
## 7	21	-1.7300940	1.11982663
## 8	18	-1.1370254	0.92507298
## 9	27	-2.3296849	0.91557787
## 10	20	-0.6732575	0.79282418
## 11	10	-2.5453331	0.77420340
## 12	5	0.2624575	0.77016712
## 13	24	-2.8618081	0.60743266
## 14	2	0.3400622	0.49758069
## 15	7	-4.8457126	0.44715743
## 16	22	1.7563206	0.43405679
## 17	25	-0.2454918	0.42648237
## 18	9	-1.6290668	0.42421642
## 19	26	-1.5767939	0.37717711

```

## 20      1 -1.3485105  0.37522992
## 21      12  4.0028668  0.25873010
## 22      28 -5.7378382  0.15266446
## 23      29 -6.8311064  0.12802599
## 24      8 -14.5629655  0.05498106
## 25     16 -1.8571480 -0.05392699
## 26     17 -3.1608488 -0.06996723
## 27      4  2.0265218 -0.07924950
## 28     11  0.5532685 -0.21970908
## 29     23  0.7854505 -0.51982463

```

2.2 Medo/Raiva

```

# 1. Definir os nomes das colunas de "Fear/Anger" (Estimulos 30 a 58)
fearanger_cols <- paste0("St_", 30:58)

# 2. Selecionar apenas essas colunas para a análise
fearanger_response_matrix <- all_responses_wide %>%
  dplyr::select(all_of(fearanger_cols))

# 3. Rodar o modelo TRI 2PL
model_fearanger <- ltm(fearanger_response_matrix ~ z1, IRT.param = TRUE)

# 4. Extrair, organizar e exibir os resultados
coef_fearanger <- as.data.frame(coef(model_fearanger))

results_fearanger <- coef_fearanger %>%
  rename(Difficulty = Dffclt, Discrimination = Dscrmmn) %>%
  rownames_to_column(var = "Stimulus_ID") %>%
  mutate(Stimulus_ID = as.numeric(str_replace(Stimulus_ID, "St_", ""))) %>%
  arrange(desc(Discrimination))

# Mostrar os resultados
print("--- Parâmetros dos Itens para Fear/Anger (ordenado por Discriminação) ---")

## [1] "--- Parâmetros dos Itens para Fear/Anger (ordenado por Discriminação) ---"

print(results_fearanger)

##   Stimulus_ID Difficulty Discrimination
## 1          35    -1.56588683    2.15400521
## 2          41    -0.93465868    2.06358014
## 3          43    -0.92178019    1.81796774
## 4          36    -1.34067678    1.72281479
## 5          31    -1.68259958    1.38036402
## 6          51    -1.31576162    1.10007384
## 7          45    -2.66841750    1.08082208
## 8          33    -1.08833360    1.01713834
## 9          42    -1.21795512    0.93457410
## 10         54    -0.79563718    0.87008335
## 11         40    -1.46732992    0.85908109

```

```

## 12      53 -1.99095159  0.77871578
## 13      57  2.96945612  0.75832293
## 14      52 -0.36638633  0.73804812
## 15      47  0.40914230  0.64502206
## 16      50 -0.07400229  0.57968455
## 17      44 -0.98770247  0.52678415
## 18      30  0.75490908  0.41756336
## 19      56 -2.49007737  0.31916801
## 20      48  0.07343733  0.28309333
## 21      34 -3.68136058  0.26750968
## 22      49 -3.48493764  0.23938082
## 23      55 -2.78270206  0.22502327
## 24      46 -4.71126480  0.14141340
## 25      39 -5.80304962  0.12639114
## 26      58 -61.20045989 -0.02265357
## 27      37 -3.55912805 -0.17513003
## 28      32  0.56727286 -0.17832202
## 29      38 -2.27871295 -0.20754759

```

2.3 Serenidade

Apenas 2 estímulos foram considerados adequados

```

# --- Análise TRI para "Serenity" ---

# 1. Definir os nomes das colunas de "Serenity" (Estímulos 59 a 87)
serenity_cols <- paste0("St_", 59:87)

# 2. Selecionar apenas essas colunas para a análise
serenity_response_matrix <- all_responses_wide %>%
  dplyr::select(all_of(serenity_cols))

# 3. Rodar o modelo TRI 2PL
model_serenity <- ltm(serenity_response_matrix ~ z1, IRT.param = TRUE)

# 4. Extrair, organizar e exibir os resultados
coef_serenity <- as.data.frame(coef(model_serenity))

results_serenity <- coef_serenity %>%
  rename(Difficulty = Dffclt, Discrimination = Dscrmn) %>%
  rownames_to_column(var = "Stimulus_ID") %>%
  mutate(Stimulus_ID = as.numeric(str_replace(Stimulus_ID, "St_", ""))) %>%
  arrange(desc(Discrimination))

# Mostrar os resultados
print("--- Parâmetros dos Itens para Serenity (ordenado por Discriminação) ---")

```

```

## [1] "--- Parâmetros dos Itens para Serenity (ordenado por Discriminação) ---"

```

```

print(results_serenity)

```

```

##   Stimulus_ID Difficulty Discrimination

```

```

## 1      68  3.04412384   1.28158515
## 2      74  3.64134246   0.70753413
## 3      70  1.49298331   0.38321480
## 4      85  0.47192170   0.12748102
## 5      59  26.36841419   0.03773165
## 6      77  5.42669538  -0.12681753
## 7      80  3.66770092  -0.17604989
## 8      62  1.26554994  -0.25896380
## 9      69  1.83159391  -0.28408637
## 10     76  1.20495665  -0.30863042
## 11     87  -1.39730426  -0.36147804
## 12     79  -0.05041367  -0.42827091
## 13     82  0.28199824  -0.61157247
## 14     83  0.03238754  -0.62994503
## 15     64  -0.03203581  -0.75299896
## 16     75  0.66074822  -0.84784840
## 17     67  1.41082123  -0.98782894
## 18     63  1.23594914  -1.00603088
## 19     78  1.21954920  -1.06023142
## 20     65  1.33669676  -1.06438960
## 21     81  0.66063357  -1.11264415
## 22     60  1.88560001  -1.14800319
## 23     72  1.17869982  -1.15277908
## 24     73  1.46855066  -1.24461058
## 25     86  1.52892833  -1.29279953
## 26     71  1.52419927  -1.49457399
## 27     66  0.54691522  -1.51400027
## 28     61  1.14749538  -1.69011792
## 29     84  0.92307193  -1.82454908

```

2.4 Tristeza

```

# 1. Definir os nomes das colunas de "Sadness" (Estímulos 88 a 116)
sadness_cols <- paste0("St_", 88:116)

# 2. Selecionar apenas essas colunas para a análise
sadness_response_matrix <- all_responses_wide %>%
  dplyr::select(all_of(sadness_cols))

# 3. Rodar o modelo TRI 2PL
model_sadness <- ltm(sadness_response_matrix ~ z1, IRT.param = TRUE)

# 4. Extraír, organizar e exibir os resultados
coef_sadness <- as.data.frame(coef(model_sadness))

results_sadness <- coef_sadness %>%
  rename(Difficulty = Dffclt, Discrimination = Dscrmn) %>%
  rownames_to_column(var = "Stimulus_ID") %>%
  mutate(Stimulus_ID = as.numeric(str_replace(Stimulus_ID, "St_", ""))) %>%
  arrange(desc(Discrimination))

# Mostrar os resultados

```

```

print("--- Parâmetros dos Itens para Sadness (ordenado por Discriminação) ---")

## [1] "--- Parâmetros dos Itens para Sadness (ordenado por Discriminação) ---"

print(results_sadness)

##   Stimulus_ID    Difficulty Discrimination
## 1          95 2.376989e-01 1.442444044
## 2          100 -1.396261e+00 1.189556904
## 3          101 -1.930251e+00 1.120197203
## 4          115 -5.929896e-01 1.101948023
## 5          111 -7.702453e-01 1.039857932
## 6          96 -1.155017e+00 0.868476174
## 7          90 -5.449360e-01 0.852128196
## 8          116 1.160149e+00 0.779811172
## 9          92 1.065258e+00 0.775811621
## 10         114 -1.438963e-01 0.763680048
## 11         88 -1.931341e+00 0.745000462
## 12         110 -1.870469e+00 0.674045911
## 13         108 -1.425989e-01 0.595477650
## 14         103 3.604645e-01 0.537683742
## 15         89 1.763832e+00 0.524438513
## 16         106 2.012291e-03 0.490563353
## 17         94 -1.216200e+00 0.418634802
## 18         97 -3.016340e+00 0.320394333
## 19         91 -2.230140e+00 0.282775967
## 20         112 -1.598377e+00 0.230597710
## 21         102 2.756249e-04 0.161907316
## 22         109 -1.007528e+01 0.059317895
## 23         93 -1.701081e+01 0.041648870
## 24         113 -9.101814e+01 0.008030253
## 25         99 4.680243e+01 0.002567058
## 26         105 -2.324536e+00 -0.034443556
## 27         107 1.352346e+00 -0.044403749
## 28         98 1.440165e+00 -0.212268187
## 29         104 -1.625883e+00 -0.488180532

```

3 Criar data frame com os melhores itens de cada categoria

```

# Criando um dataframe com os melhores itens para usar em nosso código
best_items_df <- bind_rows(
  results_happiness %>% head(10) %>% mutate(Factor = "Happiness"),
  results_fearanger %>% head(10) %>% mutate(Factor = "FearAnger"),
  results_sadness %>% head(10) %>% mutate(Factor = "Sadness")
)

# Extrair apenas os IDs dos estímulos selecionados
selected_stimuli_ids <- best_items_df$Stimulus_ID

# Ver a lista final de 30 itens
print(selected_stimuli_ids)

```

```

## [1] 6 13 15 14 19 3 21 18 27 20 35 41 43 36 31 51 45 33 42
## [20] 54 95 100 101 115 111 96 90 116 92 114

##### Passo 2: Preparar os Dados para a CFA
# Filtrar o dataframe largo para conter apenas as colunas dos melhores itens
cfa_data_final <- all_responses_wide %>%
  dplyr::select(all_of(paste0("St_", selected_stimuli_ids)))

# Declarar as variáveis como categóricas (ordenadas) para o lavaan usar o estimador WLSMV
cfa_data_final[] <- lapply(cfa_data_final, ordered)

```

4 Análise Fatorial Confirmatória das três categorias com estímulos adequados

4.1 Modelo com 3 dimensões

Já que os estímulos de serenidade tem poucos itns com discriminação adequada

```

conflicts_prefer(dplyr::filter)

## [conflicted] Will prefer dplyr::filter over any other package.

# Extrair os IDs para cada fator para facilitar a escrita
ids_happy <- best_items_df %>% filter(Factor == "Happiness") %>% pull(Stimulus_ID)
ids_fear <- best_items_df %>% filter(Factor == "FearAnger") %>% pull(Stimulus_ID)
ids_sad <- best_items_df %>% filter(Factor == "Sadness") %>% pull(Stimulus_ID)

# Criar a string do modelo manualmente
cfa_model_final_string <- '
  Happiness =~ St_6 + St_13 + St_15 + St_14 + St_19 + St_3 + St_21
  + St_18 + St_27 + St_20
  FearAnger =~ St_35 + St_41 + St_43 + St_36 + St_31 + St_51 + St_45
  + St_33 + St_42 + St_54
  Sadness   =~ St_95 + St_100 + St_101 + St_115 + St_111 + St_96
  + St_90 + St_116 + St_92 + St_114

'

# Rodar a Análise Fatorial Confirmatória
fit_cfa_final <- cfa(
  model = cfa_model_final_string,
  data = cfa_data_final,
  estimator = "wlsmv",
  ordered = T
)

# --- ANÁLISE DOS RESULTADOS ---

# 1. Verificar os Índices de Ajuste do Modelo
print("--- Índices de Ajuste do Modelo ---")

```

```

## [1] "--- Índices de Ajuste do Modelo ---"

fitmeasures(fit_cfa_final, c("chisq", "df", "pvalue", "cfi", "tli", "rmsea", "srmr"))

##   chisq      df  pvalue     cfi     tli    rmsea    srmr
## 427.268 402.000  0.185  0.989  0.988  0.018  0.123

# 2. Ver o resumo completo com as cargas fatoriais padronizadas
print("--- Resumo Completo do Modelo ---")

## [1] "--- Resumo Completo do Modelo ---"

summary(fit_cfa_final, standardized = TRUE, fit.measures = TRUE)

## lavaan 0.6-18 ended normally after 36 iterations
##
##   Estimator           DWLS
##   Optimization method NLMINB
##   Number of model parameters       63
##
##   Number of observations          200
##
## Model Test User Model:
##                               Standard      Scaled
##   Test Statistic            427.268  479.472
##   Degrees of freedom        402        402
##   P-value (Chi-square)      0.185     0.005
##   Scaling correction factor 1.610
##   Shift parameter          214.041
##   simple second-order correction
##
## Model Test Baseline Model:
##                               Standard      Scaled
##   Test statistic           2781.698 1281.194
##   Degrees of freedom        435        435
##   P-value                   0.000     0.000
##   Scaling correction factor 2.773
##
## User Model versus Baseline Model:
##                               Standard      Scaled
##   Comparative Fit Index (CFI)  0.989     0.908
##   Tucker-Lewis Index (TLI)    0.988     0.901
##
##   Robust Comparative Fit Index (CFI)      NA
##   Robust Tucker-Lewis Index (TLI)      NA
##
## Root Mean Square Error of Approximation:
##                               Standard      Scaled
##   RMSEA                  0.018     0.031
##   90 Percent confidence interval - lower 0.000     0.018
##   90 Percent confidence interval - upper  0.031     0.041
##   P-value H_0: RMSEA <= 0.050      1.000     0.999

```

```

## P-value H_0: RMSEA >= 0.080 0.000 0.000
##
## Robust RMSEA NA
## 90 Percent confidence interval - lower NA
## 90 Percent confidence interval - upper NA
## P-value H_0: Robust RMSEA <= 0.050 NA
## P-value H_0: Robust RMSEA >= 0.080 NA
##
## Standardized Root Mean Square Residual:
##
## SRMR 0.123 0.123
##
## Parameter Estimates:
##
## Parameterization Delta
## Standard errors Robust.sem
## Information Expected
## Information saturated (h1) model Unstructured
##
## Latent Variables:
##             Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## Happiness =~
##   St_6       1.000           0.639 0.639
##   St_13      1.012      0.142 0.647 0.647
##   St_15      0.923      0.178 0.590 0.590
##   St_14      0.859      0.172 0.549 0.549
##   St_19      1.155      0.190 0.738 0.738
##   St_3       0.725      0.187 0.463 0.463
##   St_21      0.942      0.159 0.602 0.602
##   St_18      0.733      0.154 0.468 0.468
##   St_27      0.811      0.176 0.518 0.518
##   St_20      0.795      0.159 0.508 0.508
## FearAnger =~
##   St_35      1.000           0.788 0.788
##   St_41      0.995      0.128 0.784 0.784
##   St_43      0.848      0.132 0.668 0.668
##   St_36      0.881      0.123 0.694 0.694
##   St_31      0.777      0.137 0.613 0.613
##   St_51      0.788      0.122 0.621 0.621
##   St_45      0.815      0.178 0.642 0.642
##   St_33      0.620      0.126 0.488 0.488
##   St_42      0.594      0.121 0.468 0.468
##   St_54      0.536      0.129 0.422 0.422
## Sadness =~
##   St_95      1.000           0.462 0.462
##   St_100     1.468      0.321 0.678 0.678
##   St_101     1.296      0.304 0.599 0.599
##   St_115     1.279      0.315 0.591 0.591
##   St_111     0.830      0.225 0.384 0.384
##   St_96      1.006      0.267 0.465 0.465
##   St_90      1.290      0.299 0.596 0.596
##   St_116     0.661      0.216 0.305 0.305
##   St_92      0.818      0.211 0.378 0.378
##   St_114     0.944      0.257 0.436 0.436

```

```

## Covariances:
##          Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## Happiness ~~
##   FearAnger      0.437  0.098   4.461  0.000   0.869  0.869
##   Sadness        0.250  0.069   3.651  0.000   0.849  0.849
## FearAnger ~~
##   Sadness        0.312  0.072   4.320  0.000   0.858  0.858
##
## Thresholds:
##          Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## St_6|t1      -1.126  0.113  -9.995  0.000  -1.126  -1.126
## St_13|t1     -0.994  0.107  -9.311  0.000  -0.994  -0.994
## St_15|t1     -0.539  0.094  -5.751  0.000  -0.539  -0.539
## St_14|t1     -0.915  0.104  -8.819  0.000  -0.915  -0.915
## St_19|t1     -1.311  0.123 -10.657  0.000  -1.311  -1.311
## St_3|t1      -0.789  0.100  -7.918  0.000  -0.789  -0.789
## St_21|t1     -0.954  0.105  -9.068  0.000  -0.954  -0.954
## St_18|t1     -0.553  0.094  -5.889  0.000  -0.553  -0.553
## St_27|t1     -1.103  0.112  -9.887  0.000  -1.103  -1.103
## St_20|t1     -0.292  0.090  -3.240  0.001  -0.292  -0.292
## St_35|t1     -1.227  0.118 -10.398  0.000  -1.227  -1.227
## St_41|t1     -0.722  0.098  -7.387  0.000  -0.722  -0.722
## St_43|t1     -0.674  0.097  -6.983  0.000  -0.674  -0.674
## St_36|t1     -0.954  0.105  -9.068  0.000  -0.954  -0.954
## St_31|t1     -1.058  0.110  -9.662  0.000  -1.058  -1.058
## St_51|t1     -0.722  0.098  -7.387  0.000  -0.722  -0.722
## St_45|t1     -1.405  0.129 -10.862  0.000  -1.405  -1.405
## St_33|t1     -0.568  0.094  -6.027  0.000  -0.568  -0.568
## St_42|t1     -0.598  0.095  -6.301  0.000  -0.598  -0.598
## St_54|t1     -0.372  0.091  -4.081  0.000  -0.372  -0.372
## St_95|t1      0.151  0.089   1.692  0.091   0.151  0.151
## St_100|t1    -0.806  0.100  -8.049  0.000  -0.806  -0.806
## St_101|t1    -1.058  0.110  -9.662  0.000  -1.058  -1.058
## St_115|t1    -0.332  0.091  -3.661  0.000  -0.332  -0.332
## St_111|t1    -0.412  0.092  -4.501  0.000  -0.412  -0.412
## St_96|t1     -0.539  0.094  -5.751  0.000  -0.539  -0.539
## St_90|t1     -0.253  0.090  -2.818  0.005  -0.253  -0.253
## St_116|t1      0.496  0.093   5.336  0.000   0.496  0.496
## St_92|t1      0.454  0.092   4.919  0.000   0.454  0.454
## St_114|t1    -0.063  0.089  -0.705  0.481  -0.063  -0.063
##
## Variances:
##          Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .St_6       0.592
## .St_13      0.582
## .St_15      0.652
## .St_14      0.699
## .St_19      0.455
## .St_3       0.786
## .St_21      0.638
## .St_18      0.781
## .St_27      0.732
## .St_20      0.742

```

```

##   .St_35      0.379      0.379      0.379
##   .St_41      0.385      0.385      0.385
##   .St_43      0.554      0.554      0.554
##   .St_36      0.518      0.518      0.518
##   .St_31      0.625      0.625      0.625
##   .St_51      0.614      0.614      0.614
##   .St_45      0.588      0.588      0.588
##   .St_33      0.762      0.762      0.762
##   .St_42      0.781      0.781      0.781
##   .St_54      0.822      0.822      0.822
##   .St_95      0.787      0.787      0.787
##   .St_100     0.540      0.540      0.540
##   .St_101     0.641      0.641      0.641
##   .St_115     0.651      0.651      0.651
##   .St_111     0.853      0.853      0.853
##   .St_96      0.784      0.784      0.784
##   .St_90      0.645      0.645      0.645
##   .St_116     0.907      0.907      0.907
##   .St_92      0.857      0.857      0.857
##   .St_114     0.810      0.810      0.810
## Happiness    0.408      0.122      3.347      0.001      1.000      1.000
## FearAnger   0.621      0.145      4.272      0.000      1.000      1.000
## Sadness      0.213      0.079      2.685      0.007      1.000      1.000

```

```

# 3. Calcular a Fidedignidade (Confiabilidade Composta - Ômega)
print("--- Fidedignidade (Confiabilidade Composta) ---")

```

```

## [1] "--- Fidedignidade (Confiabilidade Composta) ---"

```

```

compRelSEM(fit_cfa_final)

```

```

## Happiness FearAnger   Sadness
##       0.691      0.745      0.604

```

4.2 Modelo Unidimensional

Como os três fatores apresentam alta correlação e confiabilidade baixa envestigou-se o modelo unifatorial

A estrutura unidimensional se constitui de um fator em que todos os itens carregam de forma positiva consistentemente com os dados semânticos e da PANAS.

```

cfa_GFactor <- '
  # Fator Geral (G)
  G =~ St_6 + St_13 + St_15 + St_14 + St_19 + St_3 + St_21 + St_18 + St_27
  + St_20 + St_35 + St_41 + St_43 + St_36 + St_31 + St_51 + St_45 + St_33
  + St_42 + St_54 + St_95 + St_100 + St_101 + St_115 + St_111 + St_96 + St_90
  + St_116 + St_92 + St_114
'

# Rodar a CFA Bifatorial
fit_GFactor <- cfa(
  model = cfa_GFactor,

```

```

  data = cfa_data_final,
  estimator = "wlsmv",
  ordered = TRUE,
  orthogonal = TRUE # Este argumento é fundamental para o modelo bifatorial
)

summary(fit_GFactorrr, standardized = TRUE, fit.measures = TRUE)

## lavaan 0.6-18 ended normally after 27 iterations
##
##    Estimator                               DWLS
##    Optimization method                      NLMINB
##    Number of model parameters                60
## 
##    Number of observations                   200
## 
## Model Test User Model:
##                               Standard      Scaled
##    Test Statistic                         439.055   487.390
##    Degrees of freedom                      405        405
##    P-value (Chi-square)                   0.117     0.003
##    Scaling correction factor              1.618
##    Shift parameter                        216.068
##          simple second-order correction
## 
## Model Test Baseline Model:
##                               Standard      Scaled
##    Test statistic                         2781.698  1281.194
##    Degrees of freedom                      435        435
##    P-value                                0.000     0.000
##    Scaling correction factor              2.773
## 
## User Model versus Baseline Model:
##                               Standard      Scaled
##    Comparative Fit Index (CFI)            0.985     0.903
##    Tucker-Lewis Index (TLI)              0.984     0.895
## 
##    Robust Comparative Fit Index (CFI)       NA
##    Robust Tucker-Lewis Index (TLI)         NA
## 
## Root Mean Square Error of Approximation:
##                               Standard      Scaled
##    RMSEA                                0.021     0.032
##    90 Percent confidence interval - lower 0.000     0.020
##    90 Percent confidence interval - upper 0.033     0.042
##    P-value H_0: RMSEA <= 0.050           1.000     0.999
##    P-value H_0: RMSEA >= 0.080           0.000     0.000
## 
##    Robust RMSEA                           NA
##    90 Percent confidence interval - lower  NA
##    90 Percent confidence interval - upper  NA
##    P-value H_0: Robust RMSEA <= 0.050    NA
##    P-value H_0: Robust RMSEA >= 0.080    NA

```

```

##
## Standardized Root Mean Square Residual:
##
##      SRMR                               0.124      0.124
##
## Parameter Estimates:
##
##      Parameterization          Delta
##      Standard errors           Robust.sem
##      Information               Expected
##      Information saturated (h1) model   Unstructured
##
## Latent Variables:
##      Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
##      G =~
##      St_6       1.000
##      St_13      1.016  0.146   6.979  0.000   0.603   0.603
##      St_15      0.926  0.181   5.115  0.000   0.558   0.558
##      St_14      0.858  0.175   4.893  0.000   0.517   0.517
##      St_19      1.163  0.194   5.994  0.000   0.701   0.701
##      St_3       0.726  0.190   3.815  0.000   0.438   0.438
##      St_21      0.948  0.162   5.838  0.000   0.572   0.572
##      St_18      0.737  0.157   4.701  0.000   0.444   0.444
##      St_27      0.820  0.179   4.570  0.000   0.494   0.494
##      St_20      0.805  0.161   4.998  0.000   0.486   0.486
##      St_35      1.262  0.225   5.600  0.000   0.761   0.761
##      St_41      1.253  0.209   6.005  0.000   0.756   0.756
##      St_43      1.067  0.199   5.358  0.000   0.643   0.643
##      St_36      1.113  0.177   6.280  0.000   0.671   0.671
##      St_31      0.982  0.210   4.674  0.000   0.592   0.592
##      St_51      0.998  0.165   6.040  0.000   0.602   0.602
##      St_45      1.033  0.227   4.547  0.000   0.623   0.623
##      St_33      0.776  0.195   3.978  0.000   0.468   0.468
##      St_42      0.751  0.194   3.870  0.000   0.453   0.453
##      St_54      0.677  0.184   3.672  0.000   0.408   0.408
##      St_95      0.710  0.158   4.504  0.000   0.428   0.428
##      St_100     1.053  0.192   5.473  0.000   0.635   0.635
##      St_101     0.932  0.212   4.399  0.000   0.562   0.562
##      St_115     0.917  0.214   4.280  0.000   0.553   0.553
##      St_111     0.588  0.158   3.724  0.000   0.354   0.354
##      St_96      0.718  0.173   4.150  0.000   0.433   0.433
##      St_90      0.930  0.181   5.144  0.000   0.561   0.561
##      St_116     0.468  0.150   3.119  0.002   0.282   0.282
##      St_92      0.591  0.161   3.665  0.000   0.356   0.356
##      St_114     0.681  0.165   4.134  0.000   0.411   0.411
##
## Thresholds:
##      Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
##      St_6|t1    -1.126  0.113  -9.995  0.000  -1.126  -1.126
##      St_13|t1   -0.994  0.107  -9.311  0.000  -0.994  -0.994
##      St_15|t1   -0.539  0.094  -5.751  0.000  -0.539  -0.539
##      St_14|t1   -0.915  0.104  -8.819  0.000  -0.915  -0.915
##      St_19|t1   -1.311  0.123 -10.657  0.000  -1.311  -1.311
##      St_3|t1    -0.789  0.100  -7.918  0.000  -0.789  -0.789

```

```

##   St_21|t1    -0.954  0.105  -9.068  0.000  -0.954  -0.954
##   St_18|t1    -0.553  0.094  -5.889  0.000  -0.553  -0.553
##   St_27|t1    -1.103  0.112  -9.887  0.000  -1.103  -1.103
##   St_20|t1    -0.292  0.090  -3.240  0.001  -0.292  -0.292
##   St_35|t1    -1.227  0.118  -10.398 0.000  -1.227  -1.227
##   St_41|t1    -0.722  0.098  -7.387  0.000  -0.722  -0.722
##   St_43|t1    -0.674  0.097  -6.983  0.000  -0.674  -0.674
##   St_36|t1    -0.954  0.105  -9.068  0.000  -0.954  -0.954
##   St_31|t1    -1.058  0.110  -9.662  0.000  -1.058  -1.058
##   St_51|t1    -0.722  0.098  -7.387  0.000  -0.722  -0.722
##   St_45|t1    -1.405  0.129  -10.862 0.000  -1.405  -1.405
##   St_33|t1    -0.568  0.094  -6.027  0.000  -0.568  -0.568
##   St_42|t1    -0.598  0.095  -6.301  0.000  -0.598  -0.598
##   St_54|t1    -0.372  0.091  -4.081  0.000  -0.372  -0.372
##   St_95|t1    0.151   0.089   1.692   0.091   0.151   0.151
##   St_100|t1   -0.806   0.100  -8.049   0.000  -0.806  -0.806
##   St_101|t1   -1.058   0.110  -9.662   0.000  -1.058  -1.058
##   St_115|t1   -0.332   0.091  -3.661   0.000  -0.332  -0.332
##   St_111|t1   -0.412   0.092  -4.501   0.000  -0.412  -0.412
##   St_96|t1    -0.539   0.094  -5.751   0.000  -0.539  -0.539
##   St_90|t1    -0.253   0.090  -2.818   0.005  -0.253  -0.253
##   St_116|t1   0.496   0.093   5.336   0.000   0.496   0.496
##   St_92|t1    0.454   0.092   4.919   0.000   0.454  0.454
##   St_114|t1   -0.063   0.089  -0.705   0.481  -0.063  -0.063
##
## Variances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
##   .St_6      0.636
##   .St_13     0.625
##   .St_15     0.688
##   .St_14     0.733
##   .St_19     0.508
##   .St_3      0.808
##   .St_21     0.673
##   .St_18     0.803
##   .St_27     0.755
##   .St_20     0.764
##   .St_35     0.421
##   .St_41     0.429
##   .St_43     0.586
##   .St_36     0.550
##   .St_31     0.650
##   .St_51      0.638
##   .St_45     0.612
##   .St_33     0.781
##   .St_42     0.795
##   .St_54     0.833
##   .St_95     0.817
##   .St_100    0.597
##   .St_101    0.684
##   .St_115    0.694
##   .St_111    0.874
##   .St_96     0.813
##   .St_90     0.686

```

```

##      .St_116          0.920          0.920          0.920
##      .St_92           0.873          0.873          0.873
##      .St_114          0.831          0.831          0.831
##      G                0.364    0.115    3.168    0.002    1.000    1.000

fitmeasures(fit_GFactorrr, c("chisq", "df", "pvalue", "cfi", "tli", "rmsea", "srmr"))

##   chisq      df  pvalue     cfi     tli   rmsea   srmr
## 439.055 405.000  0.117  0.985  0.984  0.021  0.124

semTools:::compRelSEM(fit_GFactorrr)

##      G
## 0.864

```

4.3 Modelo Bifatorial

A estrutura bifatorial foi testada mas o modelo “quebra” porque o Fator Geral (G) “suga” quase toda a variância, deixando os fatores específicos (Happiness, Fear, Sadness) com variância zero ou negativa (os chamados Heywood Cases). É por isso que os Omegas específicos deram quase zero (0.064, 0.006).

```

cfa_bifactor_string <- '
# Fator Geral (G)
G =~ St_6 + St_13 + St_15 + St_14 + St_19 + St_3 + St_21 + St_18 + St_27
+ St_20 + St_35 + St_41 + St_43 + St_36 + St_31 + St_51 + St_45 + St_33
+ St_42 + St_54 + St_95 + St_100 + St_101 + St_115 + St_111 + St_96 + St_90
+ St_116 + St_92 + St_114

# Fatores de Grupo Específicos
Happiness =~ St_6 + St_13 + St_15 + St_14 + St_19 + St_3 + St_21 + St_18
+ St_27 + St_20
FearAnger =~ St_35 + St_41 + St_43 + St_36 + St_31 + St_51 + St_45 + St_33
+ St_42 + St_54
Sadness   =~ St_95 + St_100 + St_101 + St_115 + St_111 + St_96 + St_90
+ St_116 + St_92 + St_114
'

# Rodar a CFA Bifatorial
fit_cfa_bifactor <- cfa(
  model = cfa_bifactor_string,
  data = cfa_data_final,
  estimator = "wlsmv",
  ordered = TRUE,
  orthogonal = TRUE
)

## Warning: lavaan->lav_lavaan_step11_estoptim():
##   Model estimation FAILED! Returning starting values.

```

O modelo não convergiu, provavelmente por ser muito “dispendioso” para o tanto de dados que temos

```

compRelSEM(fit_cfa_bifactor)

##          G Happiness FearAnger   Sadness
##      0.832      0.064      0.006      0.159

```

4.4 Fator de Segunda Ordem

Rouba toda a variância dos fatores de primeira

```

# Definição do Modelo de Segunda Ordem
cfa_second_order_string <- '

Happiness =~ St_6 + St_13 + St_15 + St_14 + St_19 + St_3 + St_21
+ St_18 + St_27 + St_20
FearAnger =~ St_35 + St_41 + St_43 + St_36 + St_31 + St_51 + St_45
+ St_33 + St_42 + St_54
Sadness   =~ St_95 + St_100 + St_101 + St_115 + St_111 + St_96
+ St_90 + St_116 + St_92 + St_114

# Fator de Segunda Ordem
GAbility =~ Happiness + FearAnger + Sadness
'

# Rodar a Análise
fit_second_order <- cfa(
  model = cfa_second_order_string,
  data = cfa_data_final,
  estimator = "wlsmv",
  ordered = TRUE
)

# Ver resultados
summary(fit_second_order, standardized = TRUE, fit.measures = TRUE)

```

```

## lavaan 0.6-18 ended normally after 41 iterations
##
##   Estimator                               DWLS
##   Optimization method                     NLMINB
##   Number of model parameters             63
##
##   Number of observations                  200
##
## Model Test User Model:
##                               Standard    Scaled
##   Test Statistic                      427.268  479.472
##   Degrees of freedom                   402      402
##   P-value (Chi-square)                 0.185      0.005
##   Scaling correction factor           1.610
##   Shift parameter                     214.041
##   simple second-order correction
##
## Model Test Baseline Model:

```

```

## Test statistic 2781.698 1281.194
## Degrees of freedom 435 435
## P-value 0.000 0.000
## Scaling correction factor 2.773
##
## User Model versus Baseline Model:
## Comparative Fit Index (CFI) 0.989 0.908
## Tucker-Lewis Index (TLI) 0.988 0.901
##
## Robust Comparative Fit Index (CFI) NA
## Robust Tucker-Lewis Index (TLI) NA
##
## Root Mean Square Error of Approximation:
## RMSEA 0.018 0.031
## 90 Percent confidence interval - lower 0.000 0.018
## 90 Percent confidence interval - upper 0.031 0.041
## P-value H_0: RMSEA <= 0.050 1.000 0.999
## P-value H_0: RMSEA >= 0.080 0.000 0.000
##
## Robust RMSEA NA
## 90 Percent confidence interval - lower NA
## 90 Percent confidence interval - upper NA
## P-value H_0: Robust RMSEA <= 0.050 NA
## P-value H_0: Robust RMSEA >= 0.080 NA
##
## Standardized Root Mean Square Residual:
## SRMR 0.123 0.123
##
## Parameter Estimates:
## Parameterization Delta
## Standard errors Robust.sem
## Information Expected
## Information saturated (h1) model Unstructured
##
## Latent Variables:
## Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## Happiness =~
## St_6 1.000 0.639 0.639
## St_13 1.012 0.142 0.647 0.647
## St_15 0.923 0.178 0.590 0.590
## St_14 0.859 0.172 0.549 0.549
## St_19 1.155 0.190 0.738 0.738
## St_3 0.725 0.187 0.463 0.463
## St_21 0.942 0.159 0.602 0.602
## St_18 0.733 0.154 0.468 0.468
## St_27 0.811 0.176 0.518 0.518
## St_20 0.795 0.159 0.508 0.508
## FearAnger =~
## St_35 1.000 0.788 0.788

```

```

##   St_41      0.995  0.128  7.794  0.000  0.784  0.784
##   St_43      0.848  0.132  6.419  0.000  0.668  0.668
##   St_36      0.881  0.123  7.136  0.000  0.694  0.694
##   St_31      0.777  0.137  5.693  0.000  0.613  0.613
##   St_51      0.788  0.122  6.459  0.000  0.621  0.621
##   St_45      0.815  0.178  4.575  0.000  0.642  0.642
##   St_33      0.620  0.126  4.919  0.000  0.488  0.488
##   St_42      0.594  0.121  4.897  0.000  0.468  0.468
##   St_54      0.536  0.129  4.166  0.000  0.422  0.422
## Sadness =~
##   St_95      1.000
##   St_100     1.468  0.321  4.571  0.000  0.678  0.678
##   St_101     1.296  0.304  4.268  0.000  0.599  0.599
##   St_115     1.279  0.315  4.064  0.000  0.591  0.591
##   St_111     0.830  0.225  3.696  0.000  0.384  0.384
##   St_96      1.006  0.267  3.772  0.000  0.465  0.465
##   St_90      1.290  0.299  4.308  0.000  0.596  0.596
##   St_116     0.661  0.216  3.052  0.002  0.305  0.305
##   St_92      0.818  0.211  3.881  0.000  0.378  0.378
##   St_114     0.944  0.257  3.670  0.000  0.436  0.436
## G_Ability =~
##   Happiness  1.000
##   FearAnger  1.247  0.245  5.093  0.000  0.937  0.937
##   Sadness    0.714  0.165  4.339  0.000  0.915  0.915
##
## Thresholds:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
##   St_6|t1    -1.126  0.113 -9.995  0.000 -1.126 -1.126
##   St_13|t1   -0.994  0.107 -9.311  0.000 -0.994 -0.994
##   St_15|t1   -0.539  0.094 -5.751  0.000 -0.539 -0.539
##   St_14|t1   -0.915  0.104 -8.819  0.000 -0.915 -0.915
##   St_19|t1   -1.311  0.123 -10.657 0.000 -1.311 -1.311
##   St_3|t1    -0.789  0.100 -7.918  0.000 -0.789 -0.789
##   St_21|t1   -0.954  0.105 -9.068  0.000 -0.954 -0.954
##   St_18|t1   -0.553  0.094 -5.889  0.000 -0.553 -0.553
##   St_27|t1   -1.103  0.112 -9.887  0.000 -1.103 -1.103
##   St_20|t1   -0.292  0.090 -3.240  0.001 -0.292 -0.292
##   St_35|t1   -1.227  0.118 -10.398 0.000 -1.227 -1.227
##   St_41|t1   -0.722  0.098 -7.387  0.000 -0.722 -0.722
##   St_43|t1   -0.674  0.097 -6.983  0.000 -0.674 -0.674
##   St_36|t1   -0.954  0.105 -9.068  0.000 -0.954 -0.954
##   St_31|t1   -1.058  0.110 -9.662  0.000 -1.058 -1.058
##   St_51|t1   -0.722  0.098 -7.387  0.000 -0.722 -0.722
##   St_45|t1   -1.405  0.129 -10.862 0.000 -1.405 -1.405
##   St_33|t1   -0.568  0.094 -6.027  0.000 -0.568 -0.568
##   St_42|t1   -0.598  0.095 -6.301  0.000 -0.598 -0.598
##   St_54|t1   -0.372  0.091 -4.081  0.000 -0.372 -0.372
##   St_95|t1   0.151   0.089  1.692  0.091  0.151  0.151
##   St_100|t1  -0.806  0.100 -8.049  0.000 -0.806 -0.806
##   St_101|t1  -1.058  0.110 -9.662  0.000 -1.058 -1.058
##   St_115|t1  -0.332  0.091 -3.661  0.000 -0.332 -0.332
##   St_111|t1  -0.412  0.092 -4.501  0.000 -0.412 -0.412
##   St_96|t1   -0.539  0.094 -5.751  0.000 -0.539 -0.539
##   St_90|t1   -0.253  0.090 -2.818  0.005 -0.253 -0.253

```

```

##      St_116|t1      0.496    0.093    5.336    0.000    0.496    0.496
##      St_92|t1      0.454    0.092    4.919    0.000    0.454    0.454
##      St_114|t1     -0.063   0.089   -0.705    0.481   -0.063   -0.063
##
## Variances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
##      .St_6       0.592
##      .St_13      0.582
##      .St_15      0.652
##      .St_14      0.699
##      .St_19      0.455
##      .St_3       0.786
##      .St_21      0.638
##      .St_18      0.781
##      .St_27      0.732
##      .St_20      0.742
##      .St_35      0.379
##      .St_41      0.385
##      .St_43      0.554
##      .St_36      0.518
##      .St_31      0.625
##      .St_51      0.614
##      .St_45      0.588
##      .St_33      0.762
##      .St_42      0.781
##      .St_54      0.822
##      .St_95      0.787
##      .St_100     0.540
##      .St_101     0.642
##      .St_115     0.651
##      .St_111     0.853
##      .St_96       0.784
##      .St_90       0.645
##      .St_116     0.907
##      .St_92       0.857
##      .St_114     0.810
##      .Happiness   0.057    0.044    1.300    0.194    0.141    0.141
##      .FearAnger  0.076    0.063    1.201    0.230    0.122    0.122
##      .Sadness    0.035    0.025    1.400    0.162    0.162    0.162
##      G_Ability   0.351    0.115    3.045    0.002    1.000    1.000

fitmeasures(fit_second_order, c("chisq", "df", "pvalue", "cfi", "tli",
                                "rmsea", "srmr"))

##      chisq      df  pvalue      cfi      tli    rmsea    srmr
##  427.268 402.000   0.185   0.989   0.988   0.018   0.123

# Calcular confiabilidade (Omega) para o modelo de segunda ordem
compRelSEM(fit_second_order)

## Happiness FearAnger    Sadness
##      0.691      0.745      0.604

```

4.5 Aqui considerar só a confiabilidade do Fator Geral

A confiabilidade composta foi calculada através do coeficiente Ômega de McDonald, considerando a natureza ordinal dos dados e a estrutura de segunda ordem. O Fator Geral (G_Ability) apresentou um índice de confiabilidade excelente ($\omega = 0.923$), demonstrando alta precisão na mensuração da habilidade global de reconhecimento emocional.

Os fatores de primeira ordem também apresentaram índices adequados (Felicidade: 0.885; Medo/Raiva: 0.918; Tristeza: 0.757). Contudo, dada a elevada carga do fator geral sobre estes domínios específicos, esses índices refletem, em grande parte, a confiabilidade da variância comum (G) compartilhada pelos itens.

```
omega_G <- compRelSEM(fit_second_order, higher = "G_Ability", ord.scale = FALSE)
print(omega_G)
```

```
## Happiness FearAnger Sadness G_Ability
##      0.885      0.918      0.757      0.923
```

5 Correlação com BDI e BAI

```
## Extração dos escores fatoriais do fator de segunda ordem
```

```
# Extrair os escores do modelo de segunda ordem
fator_scores <- lavPredict(fit_second_order)

# Vamos ver o que ele gerou (deve ter Happiness, FearAnger, Sadness e G_Ability)
head(fator_scores)

##      Happiness FearAnger Sadness G_Ability
## [1,]  0.3202796 0.24999054 0.33235856 0.29813719
## [2,]  0.7571243 1.03572786 0.67675823 0.79598642
## [3,]  0.5265121 0.47999902 0.38090877 0.44899681
## [4,] -0.1236982 -0.66342665 0.04321414 -0.21920733
## [5,] -0.2616402 -0.05918781 0.06718569 -0.07457912
## [6,] -0.5375110 -0.56319338 -0.18294817 -0.40343230

# Transformar em um dataframe para facilitar
fator_scores_df <- as.data.frame(fator_scores)

# O que nos interessa é apenas a coluna "G_Ability"
# Vamos adicionar essa coluna ao seu dataframe original 'data'
# IMPORTANTE: Certifique-se de que a ordem das linhas não mudou (se não houve exclusão de dados)
data$G_Score <- fator_scores_df$G_Ability

# Verifique se deu certo
head(data %>% select(Participants, BAI, BDI, G_Score))
```

```
## # A tibble: 6 x 4
##   Participants     BAI     BDI G_Score
##   <dbl> <dbl> <dbl>   <dbl>
## 1 1       3     4  0.298
## 2 2       2     1  0.796
```

```

## 3      3    29    10  0.449
## 4      4     6     6 -0.219
## 5      5     5     7 -0.0746
## 6      6     5     8 -0.403

```

5.1 Correlações

A base de dados só tem os escores da soma de cada instrumento.

```

# --- Correlação com BAI (Ansiedade) ---
cor_bai <- cor.test(data$G_Score, data$BAI, method = "spearman")

## Warning in cor.test.default(data$G_Score, data$BAI, method = "spearman"):
## Cannot compute exact p-value with ties

print("--- Correlação entre Fator G e BAI (Spearman) ---")

## [1] "--- Correlação entre Fator G e BAI (Spearman) ---"

print(cor_bai)

##
## Spearman's rank correlation rho
##
## data: data$G_Score and data$BAI
## S = 1274144, p-value = 0.5327
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##          rho
## 0.04436792

# --- Correlação com BDI (Depressão) ---
cor_bdi <- cor.test(data$G_Score, data$BDI, method = "spearman")

## Warning in cor.test.default(data$G_Score, data$BDI, method = "spearman"):
## Cannot compute exact p-value with ties

print("--- Correlação entre Fator G e BDI (Spearman) ---")

## [1] "--- Correlação entre Fator G e BDI (Spearman) ---"

print(cor_bdi)

##
## Spearman's rank correlation rho
##
## data: data$G_Score and data$BDI
## S = 1306453, p-value = 0.7772
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##          rho
## 0.02013555

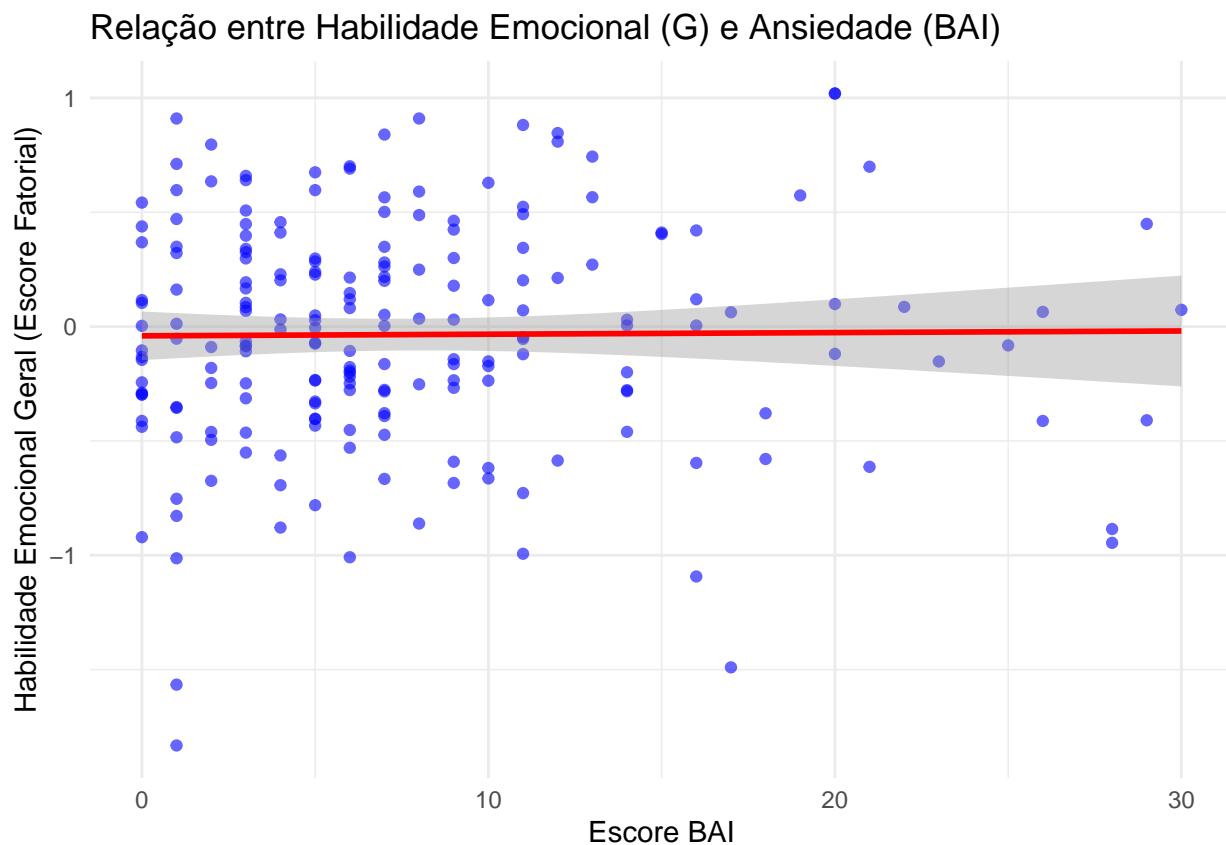
```

5.1.1 Visualização

```
library(ggplot2)

# Gráfico G-Factor vs BAI
ggplot(data, aes(x = BAI, y = G_Score)) +
  geom_point(alpha = 0.6, color = "blue") +
  geom_smooth(method = "lm", color = "red") +
  labs(title = "Relação entre Habilidade Emocional (G) e Ansiedade (BAI)",
       x = "Escore BAI", y = "Habilidade Emocional Geral (Escore Fatorial)") +
  theme_minimal()

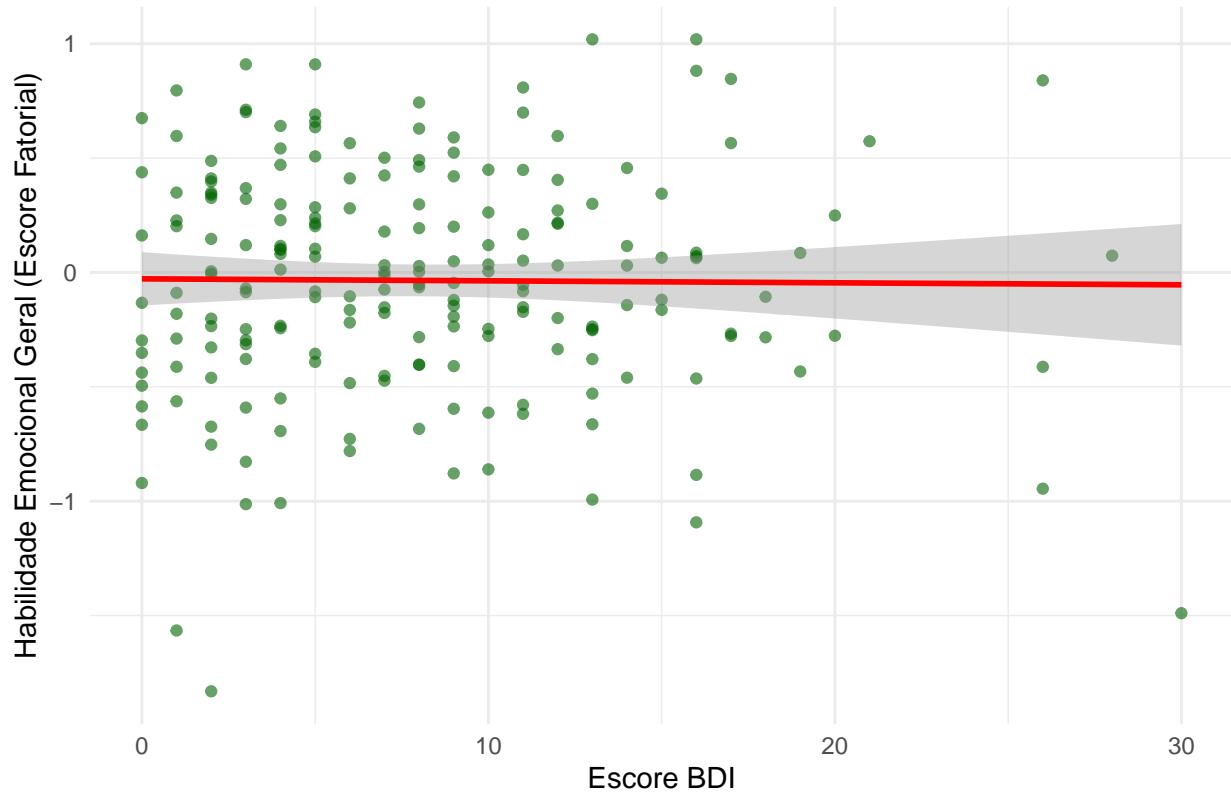
## `geom_smooth()` using formula = 'y ~ x'
```



```
# Gráfico G-Factor vs BDI
ggplot(data, aes(x = BDI, y = G_Score)) +
  geom_point(alpha = 0.6, color = "darkgreen") +
  geom_smooth(method = "lm", color = "red") +
  labs(title = "Relação entre Habilidade Emocional (G) e Depressão (BDI)",
       x = "Escore BDI", y = "Habilidade Emocional Geral (Escore Fatorial)") +
  theme_minimal()

## `geom_smooth()` using formula = 'y ~ x'
```

Relação entre Habilidade Emocional (G) e Depressão (BDI)



6 Modelos mistos

6.1 Arrumar o data

```
# 1. Recuperar a lista dos 30 melhores itens
# selected_stimuli_ids <- c(6, 13, 15, ..., 114) # Os IDs que o TRI selecionou

# 2. Filtrar o data_long para ter apenas esses itens
# E garantir que as colunas BAI e BDI estão lá
data_mixed <- data_long %>%
  filter(Stimulus_ID %in% selected_stimuli_ids) %>%
  # Garantir que a variável de resposta é numérica (0 ou 1)
  mutate(Congruence = as.numeric(Congruence)) %>%
  # Juntar com os dados clínicos (se já não estiverem no data_long)
  left_join(data %>% select(Participants, BAI, BDI), by = "Participants")

# Verifique se deu certo
names(data_mixed)
```

```
## [1] "Participants"      "Group"           "Stimulus_ID"
## [4] "Perceived_Emotion" "Congruence"       "Arousal"
## [7] "Valence"           "Intended_Emotion" "BAI"
## [10] "BDI"
```

6.2 Modelo misto para ansiedade

A chance de acerto para Medo/Raiva (intercepto) é alta e significativa. Os participantes são bons em identificar Medo e Raiva.

Sadness (-1.32, $p < .001$): o coeficiente é negativo e altamente significativo, além do Odds Ratio ser 0.266. É muito mais difícil reconhecer Tristeza do que Medo/Raiva (a chance de acerto cai para cerca de 26% da chance original).

Existe uma tendência muito leve (não significativa estatisticamente a 5%, mas $< 10\%$) de que, conforme a ansiedade aumenta, o reconhecimento de tristeza melhora ligeiramente (ou a dificuldade diminui).

Habilidade Emocional (Fator G) é independente do estado clínico atual do paciente. Ou seja, uma pessoa deprimida não “desaprende” a reconhecer emoções no seu teste. Isso sugere que o teste mede um traço estável (habilidade cognitiva) e não um estado passageiro.

```
# --- MODELO PARA ANSIEDADE (BAI) ---
model_bai <- glmer(Congruence ~ BAI * Intended_Emotion +
  (1 | Participants) + # Efeito aleatório do Participante (Intercepto)
  (1 | Stimulus_ID),    # Efeito aleatório do Item (Dificuldade)
  data = data_mixed,
  family = binomial,
  control = glmerControl(optimizer = "bobyqa")) # Ajuda a convergir

# Ver resultados
summary(model_bai)

## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: binomial ( logit )
## Formula: Congruence ~ BAI * Intended_Emotion + (1 | Participants) + (1 |
##   Stimulus_ID)
## Data: data_mixed
## Control: glmerControl(optimizer = "bobyqa")
##
##       AIC      BIC  logLik deviance df.resid
##   6003.7  6057.2 -2993.8   5987.7     5992
##
## Scaled residuals:
##       Min     1Q Median     3Q    Max
## -5.3419 -0.5235  0.3447  0.5400  3.2880
##
## Random effects:
##   Groups      Name        Variance Std.Dev.
##   Participants (Intercept) 0.9897   0.9948
##   Stimulus_ID (Intercept) 0.5178   0.7196
## Number of obs: 6000, groups: Participants, 200; Stimulus_ID, 30
##
## Fixed effects:
##                               Estimate Std. Error z value Pr(>|z|)
## (Intercept)                  1.652203   0.268791   6.147 7.91e-10 ***
## BAI                         -0.004034   0.013758  -0.293 0.769350
## Intended_EmotionHappiness    0.035425   0.347126   0.102 0.918716
## Intended_EmotionSadness     -1.325805   0.344483  -3.849 0.000119 ***
## BAI:Intended_EmotionHappiness 0.002971   0.012305   0.241 0.809224
```

```

## BAI:Intended_EmotionSadness    0.019802   0.011754   1.685 0.092035 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr) BAI     Int_EH Int_ES BAI:I_EH
## BAI      -0.397
## Intndd_EmtH -0.645  0.122
## Intndd_EmtS -0.653  0.126  0.503
## BAI:Intn_EH  0.176 -0.438 -0.278 -0.138
## BAI:Intn_ES  0.191 -0.472 -0.143 -0.265  0.513

```

```
anova(model_bai, type = "III")
```

```

## Warning in anova.merMod(model_bai, type = "III"): additional arguments ignored:
## 'type'

```

```

## Analysis of Variance Table
##                   npar  Sum Sq Mean Sq F value
## BAI                  1  0.1668  0.1668  0.1668
## Intended_Emotion      2 17.5513  8.7757  8.7757
## BAI:Intended_Emotion  2  3.4086  1.7043  1.7043

```

```
exp(fixef(model_bai))
```

```

##              (Intercept)                               BAI
##                5.218464                               0.995974
## Intended_EmotionHappiness Intended_EmotionSadness
##                1.036060                               0.265589
## BAI:Intended_EmotionHappiness BAI:Intended_EmotionSadness
##                1.002975                               1.020000

```

*# Gráfico da interação BAI * Emoção*

```
plot(ggpredict(model_bai, terms = c("BAI", "Intended_Emotion")))
```

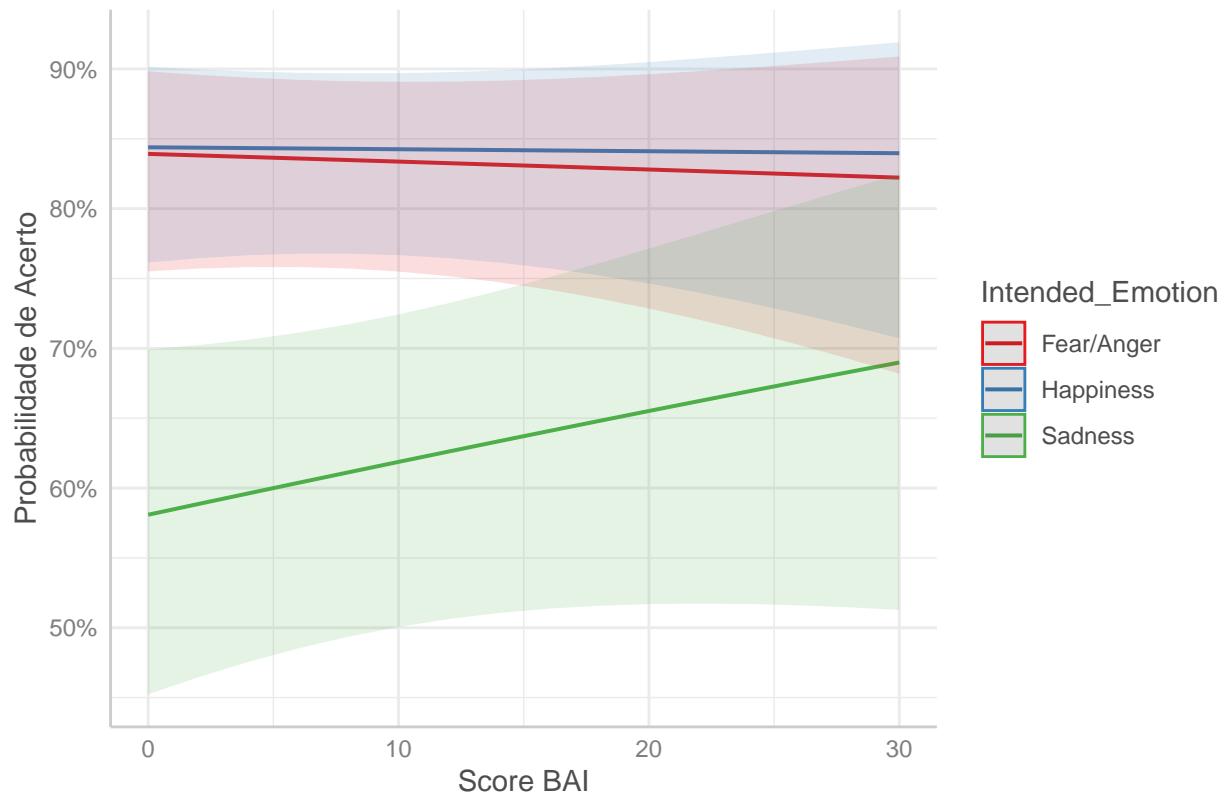
```
  labs(y = "Probabilidade de Acerto", x = "Score BAI", title = "Efeito da Ansiedade por Tipo de Emoção")
```

```

## Data were 'prettified'. Consider using `terms="BAI [all]"` to get smooth
## plots.

```

Efeito da Ansiedade por Tipo de Emoção



6.3 Modelo misto para depressão

```
# --- MODELO PARA DEPRESSÃO (BDI) ---
model_bdi <- glmer(Congruence ~ BDI * Intended_Emotion +
  (1 | Participants) +
  (1 | Stimulus_ID),
  data = data_mixed,
  family = binomial,
  control = glmerControl(optimizer = "bobyqa"))

summary(model_bdi)

## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: binomial ( logit )
## Formula: Congruence ~ BDI * Intended_Emotion + (1 | Participants) + (1 |
##   Stimulus_ID)
## Data: data_mixed
## Control: glmerControl(optimizer = "bobyqa")
##
##      AIC      BIC  logLik deviance df.resid
##  6001.0  6054.6 -2992.5   5985.0     5992
## 
```

```

## Scaled residuals:
##      Min     1Q Median     3Q    Max
## -5.3648 -0.5271  0.3450  0.5399  3.1777
##
## Random effects:
##   Groups      Name        Variance Std.Dev.
##   Participants (Intercept) 0.9914   0.9957
##   Stimulus_ID (Intercept) 0.5185   0.7201
##   Number of obs: 6000, groups: Participants, 200; Stimulus_ID, 30
##
## Fixed effects:
##                               Estimate Std. Error z value Pr(>|z|)
## (Intercept)                 1.645649  0.276570  5.950 2.68e-09 ***
## BDI                      -0.003076  0.015536 -0.198 0.843076
## Intended_EmotionHappiness  0.139228  0.352455  0.395 0.692826
## Intended_EmotionSadness    -1.352482  0.349392 -3.871 0.000108 ***
## BDI:Intended_EmotionHappiness -0.009909  0.013949 -0.710 0.477491
## BDI:Intended_EmotionSadness   0.022469  0.013414  1.675 0.093915 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr) BDI   Int_EH Int_ES BDI:I_EH
## BDI       -0.451
## Intndd_EmtH -0.635  0.142
## Intndd_EmtS -0.645  0.148  0.503
## BDI:Intn_EH  0.201 -0.445 -0.322 -0.159
## BDI:Intn_ES  0.217 -0.477 -0.164 -0.308  0.515

exp(fixef(model_bdi))

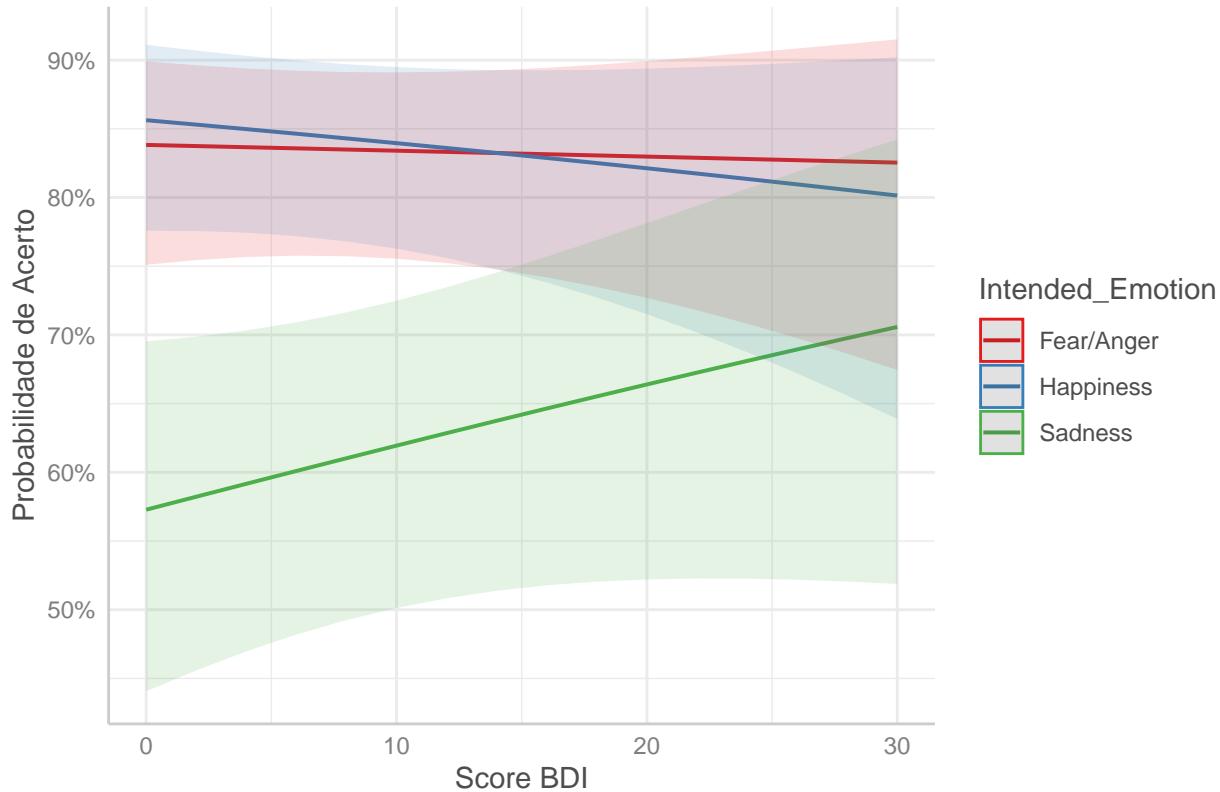
##                               (Intercept)                  BDI
##                               5.1843750                0.9969292
## Intended_EmotionHappiness Intended_EmotionSadness
##                               1.1493856                0.2585977
## BDI:Intended_EmotionHappiness BDI:Intended_EmotionSadness
##                               0.9901401                1.0227238

plot(ggpredict(model_bdi, terms = c("BDI", "Intended_Emotion")))+
  labs(y = "Probabilidade de Acerto", x = "Score BDI", title = "Efeito da Depressão por Tipo de Emoção")

## Data were 'prettified'. Consider using `terms="BDI [all]"` to get smooth
## plots.

```

Efeito da Depressão por Tipo de Emoção



Não existe diferença de reconhecimento na emoção entre grupo clínico e não clínico

```
# Vamos buscar as colunas de interpretação no dataframe original 'data'
# e juntar ao 'data_mixed' usando a coluna Participants como chave
data_mixed <- data_mixed %>%
  left_join(data %>% select(Participants, BAI_Interpretation, BDI_Interpretation),
            by = "Participants")

# Verifique se agora elas apareceram
names(data_mixed)
```

```
## [1] "Participants"      "Group"           "Stimulus_ID"
## [4] "Perceived_Emotion" "Congruence"       "Arousal"
## [7] "Valence"          "Intended_Emotion" "BAI"
## [10] "BDI"              "BAI_Interpretation" "BDI_Interpretation"
```

```
# Criar grupos binários (Ex: Moderado/Grave = 1, Mínimo/Leve = 0)
# Ajuste os números 3 e 4 baseados na sua legenda do Excel (verifique seus dados)
data_mixed <- data_mixed %>%
  mutate(
    Grupo_Depressao = ifelse(BDI_Interpretation >= 3, "Clinico", "Controle"),
    Grupo_Ansiedade = ifelse(BAI_Interpretation >= 3, "Clinico", "Controle")
  )
```

```
# Modelo para Grupo de Depressão
model_grupo_bdi <- glmer(Congruence ~ Grupo_Depressao * Intended_Emotion +
```

```

(1 | Participants) + (1 | Stimulus_ID),
data = data_mixed, family = binomial,
control = glmerControl(optimizer = "bobyqa"))

summary(model_grupo_bdi)

## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: binomial  ( logit )
## Formula:
## Congruence ~ Grupo_Depressao * Intended_Emotion + (1 | Participants) +
##   (1 | Stimulus_ID)
## Data: data_mixed
## Control: glmerControl(optimizer = "bobyqa")
##
##      AIC      BIC  logLik deviance df.resid
## 5999.6  6053.2 -2991.8   5983.6     5992
##
## Scaled residuals:
##    Min     1Q  Median     3Q    Max
## -5.3548 -0.5184  0.3452  0.5387  3.2430
##
## Random effects:
## Groups      Name        Variance Std.Dev.
## Participants (Intercept) 0.9854   0.9927
## Stimulus_ID (Intercept) 0.5183   0.7199
## Number of obs: 6000, groups: Participants, 200; Stimulus_ID, 30
##
## Fixed effects:
##                                     Estimate Std. Error z value
## (Intercept)                      1.2388   0.5121  2.419
## Grupo_DepressaoControle          0.3976   0.4684  0.849
## Intended_EmotionHappiness       -0.2563   0.5164 -0.496
## Intended_EmotionSadness         -0.4479   0.5165 -0.867
## Grupo_DepressaoControle:Intended_EmotionHappiness  0.3300   0.4133  0.798
## Grupo_DepressaoControle:Intended_EmotionSadness   -0.7529   0.4122 -1.826
## Pr(>|z|)
## (Intercept)                      0.0156 *
## Grupo_DepressaoControle          0.3959
## Intended_EmotionHappiness        0.6196
## Intended_EmotionSadness          0.3858
## Grupo_DepressaoControle:Intended_EmotionHappiness  0.4246
## Grupo_DepressaoControle:Intended_EmotionSadness   0.0678 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##           (Intr) Grp_DC Int_EH Int_ES G_DC:I_EH
## Grp_DprssCn -0.876
## Intndd_Emth -0.514  0.348
## Intndd_EmtS -0.517  0.350  0.509
## Grp_DC:I_EH  0.398 -0.454 -0.763 -0.393
## Grp_DC:I_ES  0.401 -0.460 -0.394 -0.766  0.515

```

7 Variáveis SD

```
# 1. Limpar tentativas anteriores de join incorreto (remover sufixos .x e .y se existirem)
# Isso garante que estamos trabalhando com o dataframe limpo antes de tentar de novo
data_mixed <- data_mixed %>%
  select(!matches("\\.y$")) %>% # Remove colunas terminadas em .y
  rename_with(~ str_remove(., "\\.x$"), matches("\\.x$")) # Remove o .x das originais se houver

# 2. Selecionar APENAS as variáveis NOVAS (Corrigido: removido o 'Group')
demograficos_novos <- data %>%
  dplyr::select(Participants, Sex, Age, `Years of study`, `Years of musical education`)
  # Note que removi 'Group' desta lista acima

# 3. Juntar ao data_mixed
data_mixed <- data_mixed %>%
  left_join(demograficos_novos, by = "Participants")

# 4. Verificar se funcionou (veja se 'Group' e 'Sex' aparecem corretamente)
print(names(data_mixed))
```

```
## [1] "Participants"           "Group"
## [3] "Stimulus_ID"             "Perceived_Emotion"
## [5] "Congruence"              "Arousal"
## [7] "Valence"                 "Intended_Emotion"
## [9] "BAI"                      "BDI"
## [11] "BAI_Interpretation"      "BDI_Interpretation"
## [13] "Grupo_Depressao"         "Grupo_Ansiedade"
## [15] "Sex"                      "Age"
## [17] "Years of study"          "Years of musical education"
```

```
# 5. AGORA sim, criar os fatores
data_mixed <- data_mixed %>%
  mutate(
    Group_Factor = factor(Group, levels = c(2, 1), labels = c("Nao-Musico", "Musico")),
    Sex_Factor = factor(Sex, levels = c(1, 2), labels = c("Feminino", "Masculino"))
  )

# Verifique o resultado final
head(data_mixed %>% select(Participants, Group_Factor, Sex_Factor))
```

```
## # A tibble: 6 x 3
##   Participants Group_Factor Sex_Factor
##       <dbl> <fct>     <fct>
## 1           1 Musico     Feminino
## 2           1 Musico     Feminino
## 3           1 Musico     Feminino
## 4           1 Musico     Feminino
## 5           1 Musico     Feminino
## 6           1 Musico     Feminino
```

7.1 Músicos X Não-Músicos

Não há diferença

```
model_musicos <- glmer(Congruence ~ Group_Factor * Intended_Emotion +
                         (1 | Participants) +
                         (1 | Stimulus_ID),
                         data = data_mixed,
                         family = binomial,
                         control = glmerControl(optimizer = "bobyqa"))

summary(model_musicos)

## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: binomial ( logit )
## Formula: Congruence ~ Group_Factor * Intended_Emotion + (1 | Participants) +
##           (1 | Stimulus_ID)
## Data: data_mixed
## Control: glmerControl(optimizer = "bobyqa")
##
##      AIC      BIC      logLik deviance df.resid
## 6005.3 6058.9 -2994.6   5989.3     5992
##
## Scaled residuals:
##      Min      1Q Median      3Q      Max
## -5.2201 -0.5282  0.3461  0.5412  3.3065
##
## Random effects:
## Groups      Name      Variance Std.Dev.
## Participants (Intercept) 0.9883  0.9941
## Stimulus_ID (Intercept) 0.5177  0.7195
## Number of obs: 6000, groups: Participants, 200; Stimulus_ID, 30
##
## Fixed effects:
##                                         Estimate Std. Error z value
## (Intercept)                          1.61230  0.26338  6.122
## Group_FactorMusico                  0.01613  0.18555  0.087
## Intended_EmotionHappiness          0.03250  0.34361  0.095
## Intended_EmotionSadness            -1.26341  0.34139 -3.701
## Group_FactorMusico:Intended_EmotionHappiness 0.05261  0.16892  0.311
## Group_FactorMusico:Intended_EmotionSadness    0.18139  0.15904  1.141
##                                         Pr(>|z|)
## (Intercept)                         9.27e-10 ***
## Group_FactorMusico                  0.930739
## Intended_EmotionHappiness          0.924649
## Intended_EmotionSadness            0.000215 ***
## Group_FactorMusico:Intended_EmotionHappiness 0.755444
## Group_FactorMusico:Intended_EmotionSadness    0.254061
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##             (Intr) Grp_FM Int_EH Int_ES G_FM:I_EH
## Grp_FM      1.0000
## Int_EH      -0.0000  1.0000
## Int_ES      -0.0000  0.0000  1.0000
## G_FM:I_EH   -0.0000  0.0000  0.0000  1.0000
```

```

## Grp_FctrMsc -0.352
## Intndd_EmtH -0.651  0.110
## Intndd_EmtS -0.660  0.114  0.503
## Grp_FM:I_EH  0.157 -0.447 -0.244 -0.121
## Grp_FM:I_ES  0.174 -0.490 -0.128 -0.233  0.522

```

7.2 Anos de estudo musical

Não há diferença

```

model_anos_musica <- glmer(Congruence ~ `Years of musical education` * Intended_Emotion +
  (1 | Participants) +
  (1 | Stimulus_ID),
  data = data_mixed,
  family = binomial,
  control = glmerControl(optimizer = "bobyqa"))

summary(model_anos_musica)

## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: binomial ( logit )
## Formula: Congruence ~ `Years of musical education` * Intended_Emotion +
##   (1 | Participants) + (1 | Stimulus_ID)
## Data: data_mixed
## Control: glmerControl(optimizer = "bobyqa")
##
##      AIC      BIC  logLik deviance df.resid
##  6002.2  6055.7 -2993.1    5986.2     5992
## 
## Scaled residuals:
##      Min      1Q  Median      3Q      Max
## -5.3051 -0.5278  0.3468  0.5401  3.3066
## 
## Random effects:
##   Groups      Name        Variance Std.Dev.
##   Participants (Intercept) 0.9884   0.9942
##   Stimulus_ID (Intercept) 0.5178   0.7196
## Number of obs: 6000, groups: Participants, 200; Stimulus_ID, 30
## 
## Fixed effects:
##                               Estimate Std. Error
## (Intercept)                  1.651310  0.257833
## `Years of musical education` -0.004997  0.012262
## Intended_EmotionHappiness    0.150657  0.340644
## Intended_EmotionSadness     -1.223641  0.338304
## `Years of musical education`:Intended_EmotionHappiness -0.014511  0.010989
## `Years of musical education`:Intended_EmotionSadness    0.008304  0.010538
##                               z value Pr(>|z|)
## (Intercept)                  6.405 1.51e-10 ***
## `Years of musical education` -0.408 0.683625
## Intended_EmotionHappiness    0.442 0.658292
## Intended_EmotionSadness     -3.617 0.000298 ***

```

```

## `Years of musical education`:Intended_EmotionHappiness -1.320 0.186685
## `Years of musical education`:Intended_EmotionSadness      0.788 0.430717
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr) `Yomed` Int_EH Int_ES `Yome`:I_EH
## `Yromedctn` -0.292
## Intndd_EmtH -0.658  0.089
## Intndd_EmtS -0.667  0.093  0.502
## `Yome`:I_EH  0.131 -0.450 -0.204 -0.100
## `Yome`:I_ES  0.142 -0.482 -0.104 -0.191  0.524

```

7.3 Sexo e Idade

Homens têm desempenho pior que Mulheres. Homens têm cerca de 31% menos chance de acertar do que as mulheres.

```

model_demo <- glmer(Congruence ~ Sex_Factor + Age + `Years of study` +
  (1 | Participants) +
  (1 | Stimulus_ID),
  data = data_mixed,
  family = binomial,
  control = glmerControl(optimizer = "bobyqa"))

```

```
summary(model_demo)
```

```

## Generalized linear mixed model fit by maximum likelihood (Laplace
##   Approximation) [glmerMod]
##   Family: binomial  ( logit )
## Formula:
## Congruence ~ Sex_Factor + Age + `Years of study` + (1 | Participants) +
##   (1 | Stimulus_ID)
## Data: data_mixed
## Control: glmerControl(optimizer = "bobyqa")
##
##       AIC      BIC  logLik deviance df.resid
##     6011.2  6051.4 -2999.6    5999.2      5994
## 
## Scaled residuals:
##       Min     1Q Median     3Q    Max
## -5.5010 -0.5292  0.3449  0.5391  3.1556
## 
## Random effects:
##   Groups      Name        Variance Std.Dev.
##   Participants (Intercept) 0.9537    0.9766
##   Stimulus_ID (Intercept) 0.8425    0.9179
## Number of obs: 6000, groups: Participants, 200; Stimulus_ID, 30
## 
## Fixed effects:
##                   Estimate Std. Error z value Pr(>|z|)
## (Intercept)      1.276572   0.455542   2.802  0.00507 **
## Sex_FactorMasculino -0.369128   0.155128  -2.379  0.01734 *

```

```

## Age           0.001519   0.014682   0.103  0.91762
## `Years of study` 0.006727   0.023734   0.283  0.77684
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr) Sx_FcM Age
## Sx_FctrMscl -0.102
## Age         -0.494 -0.109
## `Yrsofstdy` -0.459  0.038 -0.438

```

7.4 Músicos têm maior Habilidade Geral (G)?

```

# 1. Trazer o G_Score do dataframe original 'data' para o 'data_mixed'
data_mixed <- data_mixed %>%
  left_join(data %>% select(Participants, G_Score), by = "Participants")

# 2. Modelo Linear (LM) com o Escore Geral
# Usamos distinct() para ter apenas uma linha por participante (já que o G_Score é igual para todas as
dados_por_pessoa <- data_mixed %>%
  distinct(Participants, .keep_all = TRUE)

model_global <- lm(G_Score ~ Group_Factor + Sex_Factor + Age + `Years of study`,
                     data = dados_por_pessoa)

summary(model_global)

##
## Call:
## lm(formula = G_Score ~ Group_Factor + Sex_Factor + Age + `Years of study`,
##      data = dados_por_pessoa)
##
## Residuals:
##       Min     1Q Median     3Q    Max 
## -1.75197 -0.33133  0.02374  0.34354  1.09979 
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)    
## (Intercept) -0.077330  0.195434 -0.396   0.6928    
## Group_FactorMusico  0.018266  0.070105  0.261   0.7947    
## Sex_FactorMasculino -0.161993  0.070539 -2.297   0.0227 *  
## Age          0.002084  0.006651  0.313   0.7544    
## `Years of study`  0.003366  0.010823  0.311   0.7561    
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4951 on 195 degrees of freedom
## Multiple R-squared:  0.02774,    Adjusted R-squared:  0.007801 
## F-statistic: 1.391 on 4 and 195 DF,  p-value: 0.2384

```

7.5 Não linearidade

7.5.1 Árvore de decisão

É possível que as divisões sejam overfitting, por isso vale testar a poda, abaixo.

```
# 1. Selecionar apenas as variáveis que fazem sentido para prever o G_Score
# (Usando o dataframe 'dados_por_pessoa' que já tem o G_Score e 1 linha por sujeito)
dados_tree <- dados_por_pessoa %>%
  select(
    G_Score,
    Sex_Factor,
    Age,
    `Years of study`,
    Group_Factor,          # Músico vs Não
    `Years of musical education`,
    BAI,
    BDI
  )

# 2. Rodar a Árvore de Regressão
# cp = 0.01 é o parâmetro de complexidade padrão.
# Se a árvore não crescer, tentaremos baixar isso só pra ver se existe algum sinal fraco.
arvore <- rpart(G_Score ~ .,
                  data = dados_tree,
                  method = "anova")

# 3. Visualizar
print("--- Resumo da Árvore ---)

## [1] "--- Resumo da Árvore ---"

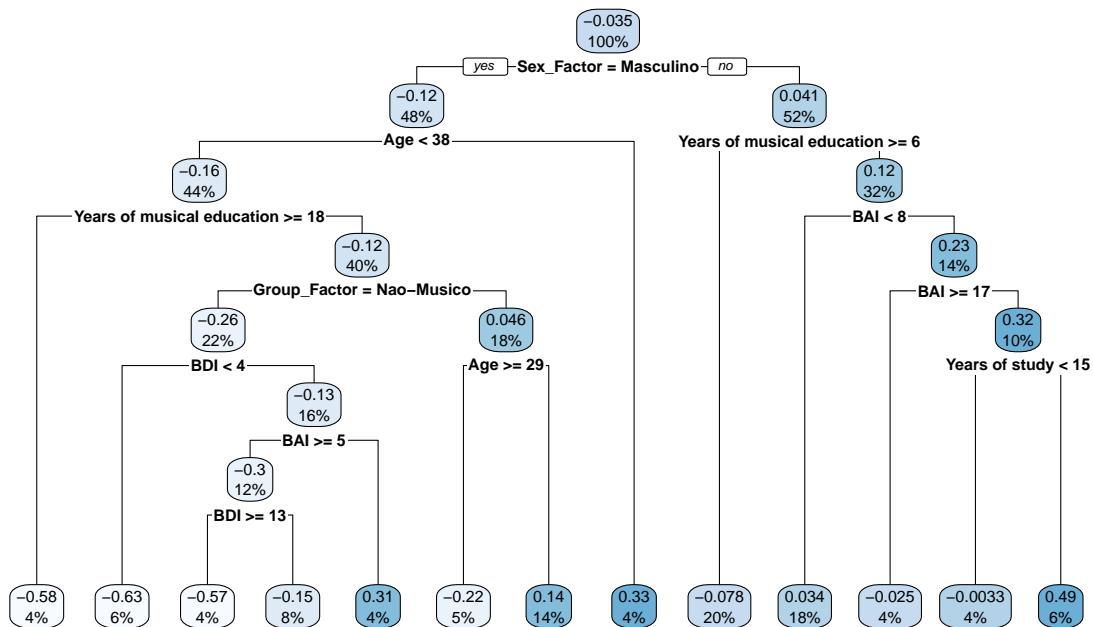
printcp(arvore) # Mostra se valeu a pena dividir os dados

##
## Regression tree:
## rpart(formula = G_Score ~ ., data = dados_tree, method = "anova")
##
## Variables actually used in tree construction:
## [1] Age                      BAI
## [3] BDI                      Group_Factor
## [5] Sex_Factor                Years of musical education
## [7] Years of study
##
## Root node error: 49.156/200 = 0.24578
##
## n= 200
##
##           CP nsplit rel error xerror      xstd
## 1  0.036511     0    1.00000 1.0075 0.11313
## 2  0.019232     6    0.78094 1.1229 0.12284
## 3  0.018716     7    0.76170 1.1845 0.11962
## 4  0.018617     8    0.74299 1.1871 0.11952
```

```
## 5 0.015555      9    0.72437 1.2098 0.11965
## 6 0.010000     12    0.67770 1.2549 0.12129
```

```
# Plotar (Se houver algo para plotar)
rpart.plot(arvore, main = "Árvore de Decisão para Habilidade Emocional (G)")
```

Árvore de Decisão para Habilidade Emocional (G)



7.5.2 Árvore com poda

A única variável preditora foi sexo, de fato.

```
# 1. Rodar a árvore "Grande" (igual você já fez, mas garantindo que ela cresça)
# Definimos um cp bem baixo (0.001) para ela crescer bastante antes de podar
arvore_completa <- rpart(G_Score ~ .,
                           data = dados_tree,
                           method = "anova",
                           control = rpart.control(cp = 0.001))

# 2. Visualizar a tabela de complexidade (Isso mostra onde o erro é menor)
printcp(arvore_completa)
```

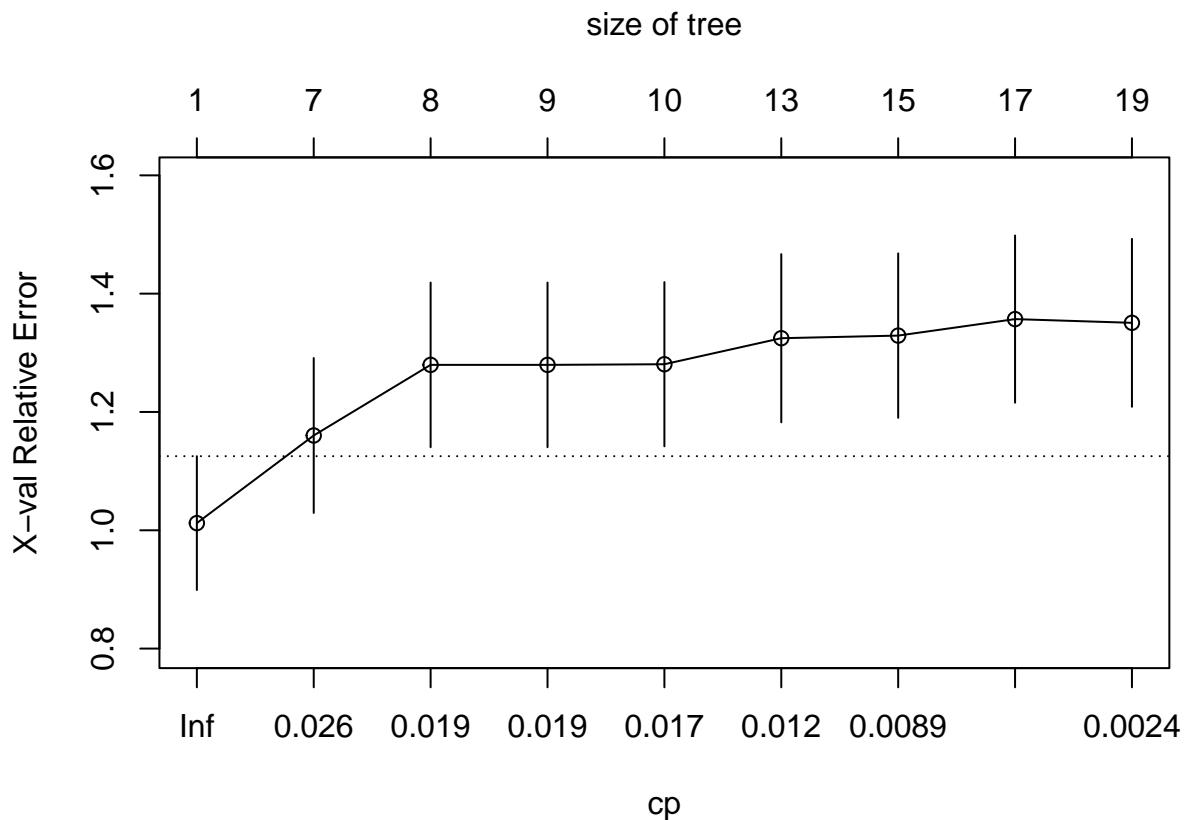
```
##
## Regression tree:
## rpart(formula = G_Score ~ ., data = dados_tree, method = "anova",
##       control = rpart.control(cp = 0.001))
```

```

## 
## Variables actually used in tree construction:
## [1] Age                      BAI
## [3] BDI                      Group_Factor
## [5] Sex_Factor               Years of musical education
## [7] Years of study
## 
## Root node error: 49.156/200 = 0.24578
## 
## n= 200
## 
##          CP nsplit rel error xerror      xstd
## 1 0.0365108     0    1.00000 1.0121 0.11315
## 2 0.0192319     6    0.78094 1.1602 0.13097
## 3 0.0187164     7    0.76170 1.2796 0.13917
## 4 0.0186172     8    0.74299 1.2796 0.13917
## 5 0.0155553     9    0.72437 1.2807 0.13882
## 6 0.0095788    12    0.67770 1.3247 0.14214
## 7 0.0081812    14    0.65855 1.3291 0.13899
## 8 0.0055303    16    0.64218 1.3570 0.14137
## 9 0.0010000    18    0.63112 1.3507 0.14196

```

```
plotcp(arvore_completa) # Gráfico do erro vs tamanho da árvore
```



```

# 3. Identificar automaticamente o melhor CP (aquele com menor erro de validação)
best_cp_index <- which.min(arvore_completa$cptable[, "xerror"])
best_cp <- arvore_completa$cptable[best_cp_index, "CP"]

# 4. Podar a árvore usando esse CP ideal
arvore_podada <- prune(arvore_completa, cp = best_cp)

# 5. Plotar a Árvore Podada (A versão "Honesto")
rpart.plot(arvore_podada,
           main = "Árvore de Decisão Podada (Estatisticamente Robusta)",
           type = 3,
           extra = 101,
           under = TRUE,
           fallen.leaves = TRUE,
           box.palette = "BuOr")

```

Árvore de Decisão Podada (Estatisticamente Robusta)

-0.035
n=200 100%

```
sessionInfo()
```

```

## R version 4.3.1 (2023-06-16)
## Platform: x86_64-apple-darwin20 (64-bit)
## Running under: macOS Monterey 12.7.6
##
## Matrix products: default
## BLAS:    /Library/Frameworks/R.framework/Versions/4.3-x86_64/Resources/lib/libRblas.0.dylib
## LAPACK:  /Library/Frameworks/R.framework/Versions/4.3-x86_64/Resources/lib/libRlapack.dylib;  LAPACK

```

```

## 
## locale:
## [1] en_US.UTF-8/en_US.UTF-8/en_US.UTF-8/C/en_US.UTF-8/en_US.UTF-8
## 
## time zone: America/Sao_Paulo
## tzcode source: internal
## 
## attached base packages:
## [1] stats      graphics   grDevices utils      datasets   methods    base
## 
## other attached packages:
## [1] ggeffects_1.7.0      randomForest_4.7-1.1 rpart.plot_3.1.2
## [4] rpart_4.1.23         sjPlot_2.8.16        lmerTest_3.1-3
## [7] lme4_1.1-35.5       Matrix_1.6-1.1      semTools_0.5-6
## [10] lavaan_0.6-18       ltm_1.2-0          polycor_0.8-1
## [13] msm_1.8.2           MASS_7.3-60         conflicted_1.2.0
## [16] lubridate_1.9.3    forcats_1.0.0       stringr_1.5.1
## [19] dplyr_1.1.4          purrr_1.0.2        readr_2.1.5
## [22] tibble_3.2.1        ggplot2_3.5.1      tidyverse_2.0.0
## [25] tidyr_1.3.1         readxl_1.4.3
## 
## loaded via a namespace (and not attached):
## [1] tidyselect_1.2.1      sjlabelled_1.2.0    farver_2.1.2
## [4] fastmap_1.2.0         TH.data_1.1-2        sjstats_0.19.0
## [7] digest_0.6.36         estimability_1.5.1  timechange_0.3.0
## [10] lifecycle_1.0.4       survival_3.7-0      magrittr_2.0.3
## [13] compiler_4.3.1       rlang_1.1.6          tools_4.3.1
## [16] utf8_1.2.6            yaml_2.3.10         knitr_1.48
## [19] labeling_0.4.3       mnormt_2.1.1        multcomp_1.4-26
## [22] expm_0.999-9        withr_3.0.2         numDeriv_2016.8-1.1
## [25] datawizard_0.10.0    grid_4.3.1          stats4_4.3.1
## [28] fansi_1.0.6           xtable_1.8-4        colorspace_2.1-1
## [31] emmeans_1.10.2       scales_1.3.0        insight_0.20.2
## [34] cli_3.6.5             mvtnorm_1.2-5       rmarkdown_2.27
## [37] generics_0.1.3        rstudioapi_0.16.0   performance_0.12.2
## [40] tzdb_0.4.0            minqa_1.2.7         cachem_1.1.0
## [43] splines_4.3.1        parallel_4.3.1     cellranger_1.1.0
## [46] vctrs_0.6.5           boot_1.3-30         sandwich_3.1-0
## [49] hms_1.1.3              glue_1.8.0          nloptr_2.1.1
## [52] admisc_0.35           codetools_0.2-20    stringi_1.8.4
## [55] gtable_0.3.5          quadprog_1.5-8      munsell_0.5.1
## [58] pillar_1.9.0           htmtools_0.5.8.1   R6_2.5.1
## [61] evaluate_0.24.0        pbivnorm_0.6.0      lattice_0.22-6
## [64] haven_2.5.4            highr_0.11          snakecase_0.11.1
## [67] memoise_2.0.1          Rcpp_1.0.14          coda_0.19-4.1
## [70] nlme_3.1-165           mgcv_1.9-1          xfun_0.52
## [73] zoo_1.8-12             sjmisc_2.8.10      pkgconfig_2.0.3

```